

Predicción Probabilística del Mundial de Fútbol FIFA 2026 mediante Gradient Boosting y Simulación Monte Carlo

David Deras

Curso de Especialización en Machine Learning

Repositorio: github.com/daiv05/fifa-world-cup-model

dc19019@ues.edu.sv

Resumen—Se presenta un sistema end-to-end para estimar la probabilidad de campeonato de cada una de las 48 selecciones que disputarán la Copa Mundial de la FIFA 2026 bajo el nuevo formato de 12 grupos. El pipeline integra cuatro fuentes heterogéneas (resultados internacionales 1872–2024, *Expected Goals* de StatsBomb, valor de mercado de Transfermarkt y ranking FIFA histórico) para construir siete características que alimentan cuatro modelos multiclase (Regresión Logística, XGBoost, LightGBM y XGBoost calibrado con Platt) entrenados con ponderación por decaimiento temporal exponencial y rebalanceo de clases. El mejor modelo (XGBoost calibrado con método Platt) obtiene un Log-Loss de 0,858 y un Brier de 0,167 sobre un conjunto de prueba temporal y se acopla a un motor Monte Carlo de 10,000 iteraciones que respeta el reglamento 2026 (2 primeros de grupo + 8 mejores terceros, desempates puntos→DG→GF, definición por penales). Los intervalos de confianza de Clopper–Pearson sitúan a un grupo reducido de selecciones históricamente fuertes entre los favoritos. Una sección dedicada discute las limitaciones del modelo: equipos debutantes sin historial, cobertura parcial de xG y ausencia de modelado estructural de lesiones.

Index Terms—Fútbol, predicción probabilística, XGBoost, Monte Carlo, ranking ELO, Mundial 2026, calibración de probabilidades.

I. INTRODUCCIÓN

La Copa Mundial de la FIFA 2026 estrena el mayor cambio estructural de su historia: 48 selecciones repartidas en 12 grupos de 4, de los cuales avanzan los dos primeros lugares más los ocho mejores terceros, totalizando 32 equipos en la fase eliminatoria. El torneo agrega una ronda adicional (*Round of 32*) y eleva el total de partidos a 104 [1]. Este cambio reglamentario invalida directamente los modelos calibrados sobre formatos de 32 equipos y motiva un rediseño del motor de simulación.

Este trabajo introduce un sistema reproducible para estimar la probabilidad de título de cada selección. Las contribuciones son: (i) un pipeline de datos automatizado que combina cuatro fuentes históricas y modernas; (ii) un benchmark de tres clasificadores multiclase entrenados con *time decay* exponencial y calibración isotónica sobre un *hold-out* temporal; (iii) un motor Monte Carlo que implementa fielmente el reglamento 2026, incluyendo el desempate de los ocho mejores terceros y la simetría local/visitante con excepción para los anfitriones; (iv) una validación histórica sobre el Mundial 2022 sin *data*

leakage y un análisis de sensibilidad a lesiones (−30 % del valor de plantilla).

II. TRABAJO RELACIONADO

El árbol genético de la predicción futbolística parte del modelo Poisson de Maher [2] y de su refinamiento Dixon–Coles [3], que captura la correlación de marcadores bajos. El sistema de puntuación Elo [4] proporciona una métrica de fuerza relativa actualizable partido a partido, hoy estandarizada para selecciones nacionales. Trabajos más recientes combinan *Random Forest* con *ratings* de equipo para Mundiales y Eurocopas [5]. La popularización de XGBoost [6] y LightGBM [7] ha desplazado la frontera hacia modelos de *gradient boosting*, mientras que SHAP [8] permite interpretar sus predicciones. Para evaluar la calibración de probabilidades el estándar son el Log-Loss y el Brier score [9], complementados con calibración isotónica o de Platt [10], [11].

III. PIPELINE DE DATOS

Los datos crudos se descargan o cargan en `src/data/` y se materializan en `data/raw/`; la limpieza y la unión producen `data/processed/features.csv`. El pipeline integra tres categorías de fuentes (datasets históricos, APIs y scraping), resumidas en la Tabla I.

Fuente principal de resultados. El dataset de Mart Jürisoo [12] disponible tanto en GitHub como en Kaggle [13] constituye el núcleo del entrenamiento con $\approx 49,000$ partidos internacionales (1872–2024). Se complementa con los resultados de Mundiales 1974–2022 [15] y los datos estructurados de openfootball [17] para validar el formato del torneo. El ranking FIFA histórico [14] y el dataset de probabilidades base WC 2026 basado en Elo [16] se usan como referencia cruzada para calibrar el feature `ranking_diff`.

Fuentes de estadísticas avanzadas. Los xG históricos provienen del *open data* de StatsBomb [18], consumido vía `statsbombpy`. Para selecciones con escasa cobertura StatsBomb se consultan FBref [21] (xA, presiones, progresiones de pase) y API-Football [19] (estadísticas de jugadores en ligas europeas). Football-Data.org [20] complementa el seguimiento de los convocados en ligas domésticas. Los ratings Elo se contrastan con EloRatings.net [23], cuyo sistema dinámico es considerado más preciso que el ranking FIFA estático. El valor

Tabla I
FUENTES DE DATOS INTEGRADAS EN EL PIPELINE

Fuente	Contenido	Cobertura
<i>Datasets históricos</i>		
martj42 [12], [13]	Resultados internacionales	1872–2024, $\approx 49\,000$ partidos
FIFA Ranking [14]	Posición y puntos	1993–2023, ≈ 210 selecc.
WC Matches [15]	Partidos Mundiales	1974–2022
WC 2026 Base-line [16]	Prob. base Elo WC 2026	48 equipos, fase grupos
openfootball [17]	Fixtures y resultados WC	Todas las ediciones
StatsBomb [18]	xG por equipo	109 selecc.
<i>APIs (datos actualizados)</i>		
API-Football [19]	Estadísticas de jugadores, xG	Ligas europeas
Football-Data.org [20]	Ligas domésticas de convocados	Europa y América
<i>Web scraping</i>		
FBref [21]	xA, presiones, progresiones	Internac. y ligas
Transfermarkt [22]	Valor de mercado plantilla	60 selecc., snapshot
EloRatings.net [23]	ELO histórico verificado	≈ 200 selecc.

de mercado de las plantillas se obtiene con un *snapshot* manual de Transfermarkt [22].

Limpieza y unión. El proceso incluye: estandarización de nombres de países a un *canonical name* (USA $\rightarrow$ United States), deduplicación por (date, home, away), geocodificación de sedes con *geopy* (distancia 0 cuando falla), *forward-fill* del ranking FIFA entre publicaciones e imputación del xG con la media global ($\approx 1,2$) para selecc. sin cobertura StatsBomb.

Licencias de datos. Los xG provienen del *open data* de StatsBomb [18], empleado bajo su licencia de uso no comercial con atribución. El valor de mercado de Transfermarkt [22] es un *snapshot* manual utilizado exclusivamente con fines académicos, sin redistribución del dato original. El resto de fuentes son datasets públicos o APIs con planes gratuitos para investigación.

IV. INGENIERÍA DE CARACTERÍSTICAS

Se construyen siete características justificadas tanto teóricamente como mediante EDA (Tabla II). El rating ELO se actualiza partido a partido siguiendo el *World Football Elo*: factor K según la importancia del torneo (Mundial 60, continentales 50, clasificatorios 40, amistosos 20), ventaja de localía de +100 puntos para el local salvo en sede neutral, y un multiplicador por diferencia de goles que amplifica el ajuste en marcadores contundentes. La Fig. 2 ilustra la dinámica del ELO en cinco selecciones representativas; la Fig. 4 muestra colinealidad alta

Tabla II
CARACTERÍSTICAS DEL MODELO Y SU JUSTIFICACIÓN

Feature	Justificación
elo_diff	ELO local – ELO visitante; métrica dinámica superior al ranking FIFA estático [4]
squad_value_diff	$\log(\text{val}_L) - \log(\text{val}_V)$; proxy de calidad de plantilla
xg_avg_for	xG prom. a favor: local – visitante; eficiencia ofensiva
xg_avg_against	xG prom. en contra: local – visitante; solidez defensiva
travel_dist_home	km de la capital del local a la sede; fatiga de viaje
travel_dist_away	Ídem para el visitante
ranking_diff	$\text{rank}_V - \text{rank}_L$; saltos del ranking FI-FA




Figura 1. Distribución de *elo_diff* por clase de resultado (H/E/V). La separación monotónica entre las tres distribuciones respalda el poder predictivo del feature.




Figura 2. Evolución del rating ELO para cinco selecciones representativas a lo largo de cuatro décadas.

entre *elo_diff* y *ranking_diff* ($r \approx 0,84$), mientras que el resto de pares se mantiene en niveles moderados.

IV-A. Decaimiento temporal y ponderación de clases

Cada partido contribuye al entrenamiento con un peso

$$W(t) = e^{-\lambda \Delta t} \cdot c_{y_i}, \quad \lambda = 1 \times 10^{-3} \text{ días}^{-1}, \quad (1)$$

donde Δt son los días entre la fecha del partido y la más reciente del dataset, y c_{y_i} es el peso *balanced* de *sklearn* sobre la etiqueta $y_i \in \{H, E, V\}$. Esto corrige el desbalance natural $H \approx 49\%$, $E \approx 21\%$, $V \approx 30\%$ (Fig. 3) y prioriza la señal reciente. Los pesos se renormalizan por su media para que el aprendizaje permanezca a escala unitaria.




Figura 3. Distribución de la variable objetivo. El desbalance hacia la clase *Local* motiva la ponderación `class_weight=balanced`.

V. MODELADO

El problema se formula como clasificación multiclase a nivel de partido $\{H, E, V\}$. Se entrenan tres modelos: Regresión Logística multinomial (*baseline*, con `StandardScaler`), XGBoost (`multi:softprob`) y LightGBM. La búsqueda de hiperparámetros emplea Optuna [24] con 100 *trials* y `TimeSeriesSplit(n = 5)` interno sobre el conjunto de entrenamiento, optimizando `neg_log_loss`, con poda por mediana (*MedianPruner*) para abortar *trials* poco prometedores y un muestreador sembrado que garantiza reproducibilidad. La Fig. 5 resume la importancia SHAP agregada (mean |SHAP|) y muestra que `elo_diff` domina ($\approx 0,39$), seguido por `ranking_diff` ($\approx 0,13$); las features de xG se sitúan en un segundo nivel ($\approx 0,03$ c/u), mientras que `squad_value_diff` ($\approx 0,01$) y `travel_distance_away` ($\approx 0,01$) aportan marginalmente. `travel_distance_home` es nulo ($\approx 0,00$): es de hecho constante (100 % de ceros) en esta configuración con geocodificación desactivada, por lo que el modelo opera sobre seis features efectivas.

V-A. División temporal del dataset

Se evita rigurosamente el *data leakage* mediante un split estrictamente temporal (Tabla III). La calibración Platt (sigmoid) del XGBoost se ajusta sobre la franja 2021 (validación) para no contaminar el conjunto de prueba. El método sigmoid es más estable que el isotónico cuando el conjunto de validación es pequeño (un año de datos, tres clases), evitando sobreajuste en la curva de calibración.

Recorte mínimo. El entrenamiento usa partidos con `date` ≥ 2010 , aunque `features.csv` contiene datos desde 1993. Los features estáticos (xG, valor de plantilla, ranking moderno) no son representativos del fútbol pre-2010, y el time decay con $\lambda = 0,001$ ya reduce el peso de esos partidos a menos del 2 %. El ELO sigue calculándose sobre el histórico completo para mayor precisión.

Tabla III
SPLIT TEMPORAL Y USO DE CADA CONJUNTO

Conjunto	Filtro	Uso
Train	<code>date < 2021-01-01</code>	LogReg, XGBoost, LightGBM
Validación	<code>2021-01-01 ≤ date < 2022-01-01</code>	Calibración isotónica
Test	<code>date ≥ 2022-01-01</code>	Evaluación final

Doble pipeline. Para validar el Mundial 2022 sin leakage se re-ejecuta el entrenamiento con `cutoff = 2022-01-01`, produciendo `xgboost_pre2022.joblib`. Cuando este `cutoff` vacía el conjunto de validación temporal, se activa un *fallback* 85/15 que reserva el último 15 % temporal del *train* para la calibración.

VI. MOTOR DE SIMULACIÓN DEL TORNEO

El motor (`src/simulation/`) ejecuta $N=10,000$ realizaciones del torneo completo (104 partidos $\times N=1,04 \times 10^6$ partidos simulados). Cada partido i, j pasa por las siguientes etapas:

1. **Probabilidades simétricas.** Salvo cuando uno de los equipos es anfitrión jugando en su país, se promedia $P(i \text{ vs } j)$ con la inversión de $P(j \text{ vs } i)$ para eliminar el sesgo home/away heredado del dataset.
2. **Marcador y outcome.** El *outcome* $\{H, E, V\}$ se sortea con las probabilidades del modelo. En fase de grupos se generan goles $g_i \sim \text{Poisson}(\mu_i)$, $g_j \sim \text{Poisson}(\mu_j)$ con μ basado en xG a favor/en contra, y el marcador se ajusta para ser coherente con el outcome (desempates por DG/GF).
3. **Fase de grupos.** 12 grupos de 4; clasifican los dos primeros más los 8 mejores terceros, con desempates puntos $\rightarrow$ diferencia de goles $\rightarrow$ goles a favor según el reglamento FIFA 2026 [1].
4. **Eliminatorias.** Round of 32 $\rightarrow$ Round of 16 $\rightarrow$ Cuartos $\rightarrow$ Semifinales $\rightarrow$ Final. Si hay empate tras los 90', la definición por penales se modela como Bernoulli(0,5).

Se contabilizan, por equipo, las veces que alcanza cada ronda y los intervalos de confianza al 95 % se calculan con el método binomial exacto de Clopper-Pearson [25] vía `scipy.stats.beta`.

VII. EVALUACIÓN

Se reportan Log-Loss y Brier score sobre el conjunto de prueba (`date` ≥ 2022). Se evita *accuracy* por ser inadecuada para predicciones probabilísticas desbalanceadas [9].

Nota metodológica sobre el Brier. El valor reportado es el promedio de los tres scores binarios *one-vs-rest* (cada clase $\{H, E, V\}$ contra el resto), de modo que se sitúa en el rango $[0, 1]$ y no en la formulación multiclase de suma de diferencias cuadráticas (rango $[0, 2]$). Ambas medidas son equivalentes




Figura 4. Matriz de correlación de las siete características. Se observa colinealidad alta entre `elo_diff` y `ranking_diff`; el resto de pares se mantiene en rangos moderados.




Figura 5. Resumen SHAP agregado (mean |SHAP|) del XGBoost. `elo_diff` domina la contribución, con `ranking_diff` en segundo lugar y las features de xG en un tercer nivel; `travel_distance_home` es nulo.

salvo un factor: el Brier de suma multiclase es K veces el promediado, con $K = 3$ clases; así, el 0,167 reportado corresponde a 0,501 en la escala $[0, 2]$.

La Tabla IV muestra que XGBoost calibrado es el mejor modelo en ambas métricas — el único que supera a todos los demás simultáneamente en Log-Loss y Brier. La calibración Platt sobre datos de validación 2021 corrige la sobreconfianza del XGBoost base sin degradar su discriminación. Entre los modelos sin calibrar, XGBoost lidera (0,8808/0,1732), seguido de cerca por LogReg (0,8855/0,1736) gracias al rebalanceo de clases y el time decay; LightGBM queda último (0,8958), lo

Tabla IV
MÉTRICAS DE EVALUACIÓN SOBRE TEST TEMPORAL (≥ 2022)

Modelo	Log-Loss ↓	Brier ↓
XGBoost-Cal	0,8581	0,1670
XGBoost	0,8808	0,1732
LogReg	0,8855	0,1736
LightGBM	0,8958	0,1770




Figura 6. Curvas de calibración por clase. Todos los modelos se aproximan bien a la diagonal en *Away Win* y *Home Win*; la clase *Draw* queda sub-calibrada en todos — reflejo directo de la baja correlación entre features y empates ($|r| < 0,07$).

que sugiere un ligero sobreajuste frente a la regularización implícita de los otros dos.

VII-A. Estudio de ablación

Para cuantificar la contribución marginal de las features más discutidas (xG y valor de plantilla) se reentrena el XGBoost calibrado manteniendo fijos el split temporal, los pesos (*time decay* + *balanced*) y los hiperparámetros óptimos; lo único que varía entre filas es el conjunto de features. La Tabla V con-

Tabla V
ABLACIÓN DE GRUPOS DE FEATURES (XGBOOST CALIBRADO, TEST ≥ 2022)

Configuración	Log-Loss	Brier	ΔLL	$\Delta Brier$
Completo (7 feat.)	0,8581	0,1670	—	—
Sin xG	0,8608	0,1675	+0,0027	+0,0005
Sin squad_value	0,8574	0,1668	−0,0007	−0,0002

Tabla VI
TOP-10 CANDIDATOS A CAMPEÓN (10 000 ITERACIONES)

Equipo	P(Campeón)	IC 95 %
España	16,01 %	[15,30, 16,74]
Argentina	10,94 %	[10,33, 11,57]
Francia	10,38 %	[9,79, 10,99]
Brasil	7,80 %	[7,28, 8,34]
Inglaterra	7,72 %	[7,20, 8,26]
Japón	3,57 %	[3,21, 3,95]
Portugal	3,41 %	[3,06, 3,78]
Países Bajos	3,29 %	[2,95, 3,66]
México	3,14 %	[2,81, 3,50]
Estados Unidos	2,72 %	[2,41, 3,06]

firma que el grupo de xG aporta la mayor señal marginal: retirarlo degrada ambas métricas (+0,0027 en Log-Loss, +0,0005 en Brier). `squad_value_diff`, en cambio, es *redundante*: eliminarlo incluso *mejora* levemente el test (−0,0007 en Log-Loss, −0,0002 en Brier), dentro del ruido pero sin aportar señal por encima del núcleo `elo_diff/ranking_diff`. Esto es coherente con su última posición entre las features informativas en el análisis SHAP (Fig. 5) y con la baja sensibilidad ante reducciones de plantilla (Tabla VIII); se mantiene por su justificación teórica (capacidad económica vs. forma deportiva) y su coste nulo.

Validación histórica. El modelo `xgboost_pre2022` (entrenado exclusivamente con `date<2022-01-01`) se evaluó sobre los partidos del Mundial 2022, sirviendo como prueba *out-of-time* sin contaminación. Los resultados numéricos se imprimen en consola al ejecutar `make evaluate`.

VIII. RESULTADOS DE LA SIMULACIÓN

La Tabla VI lista el Top-10 de candidatos al título y la Tabla VII resume la progresión por fase de los tres anfitriones, ambos con intervalos Clopper–Pearson al 95 %. España encabeza con claridad (16,0 %); le siguen Argentina (10,94 %) y Francia (10,38 %) con intervalos solapados ([10,33, 11,57] y [9,79, 10,99]), por lo que su orden no es estadísticamente distinguible (empate técnico). Lo mismo ocurre entre Brasil (7,80 %) e Inglaterra (7,72 %). Entre los anfitriones, México (3,14 %) supera a Estados Unidos (2,72 %) y Canadá (2,48 %); la ventaja de local es nítida en la fase de grupos (R32 entre 86 y 95 %) pero se diluye en rondas avanzadas.

VIII-A. Análisis de sensibilidad a lesiones

Aunque las lesiones no se modelan estructuralmente, el script `src/analysis/sensitivity.py` aplica una per-

Tabla VII
PROGRESIÓN POR FASE DE LOS ANFITRIONES (%, IC 95 %)

Fase	México	EE.UU.	Canadá
Round of 32	94,7	85,5	95,4
Round of 16	59,5	44,1	52,2
Cuartos	28,7	24,3	27,5
Semifinales	14,3	12,2	12,6
Final	7,0	5,6	5,7
Campeón	3,1	2,7	2,5

Tabla VIII
SENSIBILIDAD A UNA REDUCCIÓN DEL 30 % EN EL VALOR DE PLANTILLA

Equipo	Base %	Lesión %	Δ pp
España	16,01	15,31	−0,70
Argentina	10,94	10,50	−0,44
Francia	10,38	9,65	−0,73
Brasil	7,80	7,33	−0,47
Inglaterra	7,72	7,50	−0,22

turbación de −30 % sobre `squad_value` para cada equipo del top-5 y re-ejecuta la simulación. La Tabla VIII muestra que el efecto es modesto y consistentemente negativo (−0,22 a −0,73 pp). Esto es coherente con la importancia SHAP: `squad_value_diff` ocupa la quinta posición (Fig. 5), muy por debajo de `elo_diff` y `ranking_diff`. El motor reutiliza la misma semilla (*números aleatorios comunes*) entre el escenario base y el perturbado, de modo que el Δ aisla el efecto de la reducción de plantilla con baja varianza, sin el ruido estocástico que afectaría a una comparación con semillas independientes.

IX. LIMITACIONES

El modelo presenta siete limitaciones reconocidas:

1. **Debutantes.** Equipos como Uzbekistán, Curazao o Cabo Verde tienen historial internacional escaso; su ELO se inicializa con el valor neutro 1500 y converge lentamente, lo que probablemente *infla* su probabilidad relativa frente a rivales subestimados de la misma confederación.
2. **Calibración ELO entre confederaciones.** El sistema ELO es de suma cero dentro de cada componente conexo de rivales; como los partidos inter-confederación son escasos (esencialmente Mundiales y amistosos), la escala *relativa* entre confederaciones queda débilmente anclada. El *update* ELO ya incorpora ventaja de localía (+100 al local salvo en sede neutral) y un multiplicador por diferencia de goles, ambos estándar en el *World Football Elo*; estas correcciones atenúan el sesgo —la probabilidad de título de Japón bajó de $\approx 4,1$ % a 3,6 %, ya claramente por debajo del bloque de favoritos— pero no lo eliminan: las selecciones AFC fuertes en su zona siguen agrupándose alto (Japón ≈ 1998 , Corea del Sur ≈ 1943 , Australia ≈ 1931 , Irán ≈ 1925) porque los choques de alto K-factor (p.ej. Japón venciendo a

Alemania y España en 2022, $K = 60$) inyectan saltos que regresan despacio. El *feature ranking_diff* atenúa adicionalmente el sesgo al aportar la ponderación cruzada del ranking FIFA. Un arreglo dirigido serían *off-sets* por confederación estimados de los resultados inter-confederación, aunque arriesga penalizar a selecciones AFC genuinamente fuertes; el ancla última es disponer de más juego inter-confederación, que solo el Mundial aporta.

3. **Cobertura xG.** El *open data* de StatsBomb [18] privilegia torneos UEFA/CONMEBOL; las selecciones sin cobertura reciben un xG por defecto de 1,2 (la media global). En el fixture WC2026 esto afecta a **13 de 48 selecciones** (~27 %, incluyendo Noruega, Costa de Marfil, Argelia y Uzbekistán), que se simulan con un ataque y defensa promedio. Como la clasificación de grupos y la selección de los ocho mejores terceros dependen de la diferencia y los goles a favor, esta imputación inyecta ruido que se propaga hasta 8 de los 32 cruces de la fase eliminatoria.
4. **Snapshot Transfermarkt.** El valor de mercado es una fotografía manual a una fecha fija (no *live scraping*); cambios posteriores (transferencias, retiros) no se reflejan hasta el siguiente *snapshot*.
5. **Geocodificación.** Cuando la sede del partido no es geocodificable se asigna *travel_distance = 0*, indistinguible de un campo neutro o de un partido en casa, lo que diluye levemente la señal de fatiga.
6. **Lesiones de última hora.** No hay modelado estructural de bajas individuales; el *sensitivity.py* es únicamente un *stress test* agregado sobre *squad_value*. Una baja clave en una posición específica (e.g., portero titular) tiene un impacto que el modelo no puede capturar.
7. **Snapshot del ranking FIFA desactualizado.** El dataset de ranking termina el 2024-06-20, unos 18 meses antes de la *REFERENCE_DATE* (2026-01-01) y del último partido de entrenamiento (2026-03-31). Como *ranking_diff* se resuelve con el último rango disponible ($\leq$ fecha del partido), los partidos recientes —los de mayor peso por *time decay*— heredan rangos congelados en mediados de 2024; p.ej. España figura en el puesto 8 (pre-Eurocopa 2024) pese a que su ELO la sitúa primera. El impacto es acotado porque *ranking_diff* ocupa un papel secundario ($\text{mean}|SHAP| \approx 0,13$, frente a 0,39 de *elo_diff*) y las selecciones sin entrada caen a un rango por defecto (78). Como artefacto menor de la fuente, dos selecciones comparten el puesto 12 (Colombia y Marruecos). Refrescar el *snapshot* a una versión 2025–2026 corregiría el desfase.

X. REPRODUCIBILIDAD

El repositorio mantiene una arquitectura modular bajo *src/* (*data/*, *features/*, *models/*, *simulation/*, *analysis/*, *visualization/*), con CSVs versiona-

bles producidos en *data/processed/* y figuras en *reports/figures/*. Toda la cadena se reproduce con:

```
pip install -e .
make all      # features -> train -> evaluate
              # -> ablation -> simulate
              # -> sensitivity
streamlit run \
  src/visualization/dashboard.py
```

Toda la cadena es **determinista**: la búsqueda Optuna usa un muestreador sembrado, los modelos fijan *random_state*, y el motor Monte Carlo deriva una semilla hija por bloque (*SeedSequence*), de modo que el resultado es idéntico bit a bit en cada ejecución e *independiente* del número de procesos paralelos. La cobertura de pruebas (*pytest tests/ -v*) valida la mecánica del ELO, la lógica de desempates de grupos, el muestreo Poisson de goles y la invariancia de la simulación frente al paralelismo. Un *dashboard* Streamlit se publica en <https://fifa-world-cup-model.streamlit.app/>.

XI. CONCLUSIONES Y TRABAJO FUTURO

Se ha presentado un sistema reproducible para predecir la Copa Mundial 2026 que cumple con los requisitos planteados: múltiples fuentes limpias, siete características justificadas por EDA y SHAP, *benchmark* de cuatro modelos con calibración Platt sobre validación temporal y un motor Monte Carlo de 10,000 iteraciones fiel al nuevo reglamento. El XGBoost calibrado logra Log-Loss de 0,858 y Brier de 0,167 —mejor en ambas métricas simultáneamente. Las simulaciones ubican a España (16,0 %) como favorita clara, seguida de Argentina (10,9 %) y Francia (10,4 %) en un empate técnico (intervalos de confianza solapados que impiden ordenarlas), y de un segundo grupo con Brasil e Inglaterra (~7,8 %). Los tres anfitriones alcanzan probabilidades de título entre 2,5 % y 3,1 %, con ventaja de local coherente en rondas iniciales ($R32 \geq 86$ %) pero convergencia en etapas avanzadas.

Trabajo futuro: (i) incorporar un modelo Dixon–Coles [3] para los marcadores en lugar de Poisson independiente; (ii) reemplazar el *snapshot* Transfermarkt por un *scraper* programado; (iii) acelerar el bucle Monte Carlo con NumPy vectorizado o un binario en Rust invocado vía FFI, lo que permitiría escalar a $10^5 - 10^6$ iteraciones; y (iv) modelar lesiones a nivel de jugador integrando *features* de minutos disputados y posición.

REFERENCIAS

- [1] Fédération Internationale de Football Association, “FIFA World Cup 2026 competition format and regulations,” 2023. [Online]. Available: <https://www.fifa.com/fifaplus/en/tournaments/mens/worldcup/canadamexicousa2026> (accessed 2026-05-24).
- [2] M. J. Maher, “Modelling association football scores,” *Statistica Neerlandica*, vol. 36, no. 3, pp. 109–118, 1982, doi: <https://doi.org/10.1111/j.1467-9574.1982.tb00782.x>.
- [3] M. J. Dixon and S. G. Coles, “Modelling association football scores and inefficiencies in the football betting market,” *Journal of the Royal Statistical Society: Series C (Applied Statistics)*, vol. 46, no. 2, pp. 265–280, 1997, doi: <https://doi.org/10.1111/1467-9876.00065>.
- [4] A. E. Elo, *The Rating of Chessplayers, Past and Present*. New York: Arco Publishing, 1978.

- [5] A. Groll, C. Ley, G. Schaubberger, and H. Van Eetvelde, "A hybrid random forest to predict soccer matches in international tournaments," *J. Quant. Anal. Sports*, vol. 15, no. 4, pp. 271–287, 2019, doi: <https://doi.org/10.1515/jqas-2018-0060>.
- [6] T. Chen and C. Guestrin, "XGBoost: A scalable tree boosting system," in *Proc. 22nd ACM SIGKDD Int. Conf. on Knowledge Discovery and Data Mining*, 2016, pp. 785–794, doi: <https://doi.org/10.1145/2939672.2939785>.
- [7] G. Ke *et al.*, "LightGBM: A highly efficient gradient boosting decision tree," in *Adv. Neural Inf. Process. Syst. (NeurIPS)*, vol. 30, 2017.
- [8] S. M. Lundberg and S.-I. Lee, "A unified approach to interpreting model predictions," in *Adv. Neural Inf. Process. Syst. (NeurIPS)*, vol. 30, 2017.
- [9] G. W. Brier, "Verification of forecasts expressed in terms of probability," *Monthly Weather Review*, vol. 78, no. 1, pp. 1–3, 1950, doi: [https://doi.org/10.1175/1520-0493\(1950\)078<0001:VOFET>2.0.CO;2](https://doi.org/10.1175/1520-0493(1950)078<0001:VOFET>2.0.CO;2).
- [10] J. C. Platt, "Probabilistic outputs for support vector machines and comparisons to regularized likelihood methods," in *Advances in Large Margin Classifiers*, 1999, pp. 61–74.
- [11] A. Niculescu-Mizil and R. Caruana, "Predicting good probabilities with supervised learning," in *Proc. 22nd Int. Conf. on Machine Learning (ICML)*, 2005, pp. 625–632, doi: <https://doi.org/10.1145/1102351.1102430>.
- [12] M. Jürisoo, "International football results from 1872 to 2024," 2024. [Online]. Available: https://github.com/martj42/international_results (accessed 2026-05-24).
- [13] M. Jürisoo, "International football results from 1872 to 2024," *Kaggle*, 2024. [Online]. Available: <https://www.kaggle.com/datasets/martj42/international-football-results-from-1872-to-2017> (accessed 2026-05-24).
- [14] cashncarry, "FIFA world ranking 1993–2023," *Kaggle*, 2023. [Online]. Available: <https://www.kaggle.com/datasets/cashncarry/fifaworldranking> (accessed 2026-05-24).
- [15] I. Shahrukh, "FIFA world cup matches 1974–2022," *Kaggle*, 2023. [Online]. Available: <https://www.kaggle.com/datasets/ibrahimshahrukh/fifa-world-cup-matches-19742022-dataset> (accessed 2026-05-24).
- [16] S. Zahran, "WC2026 match probability baseline dataset," *Kaggle*, 2024. [Online]. Available: <https://www.kaggle.com/datasets/sarazahran1/wc2026-match-probability-baseline-dataset> (accessed 2026-05-24).
- [17] openfootball contributors, "World cup data repository," GitHub, 2024. [Online]. Available: <https://github.com/openfootball/worldcup> (accessed 2026-05-24).
- [18] StatsBomb, "StatsBomb open data," 2024. [Online]. Available: <https://github.com/statsbomb/open-data> (accessed 2026-05-24).
- [19] RapidAPI / API-Football, "API-Football: Football statistics and live scores," 2024. [Online]. Available: <https://rapidapi.com/collection/football-soccer> (accessed 2026-05-24).
- [20] Football-Data.org, "Football data and results," 2024. [Online]. Available: <https://www.football-data.org/> (accessed 2026-05-24).
- [21] Sports Reference LLC, "FBref: Football statistics and history," 2024. [Online]. Available: <https://fbref.com/en/> (accessed 2026-05-24).
- [22] Transfermarkt, "National teams market values," 2026, manual snapshot. [Online]. Available: <https://www.transfermarkt.com> (accessed 2026-05-24).
- [23] EloRatings.net, "World football Elo ratings," 2024. [Online]. Available: <https://www.eloratings.net/> (accessed 2026-05-24).
- [24] T. Akiba, S. Sano, T. Yanase, T. Ohta, and M. Koyama, "Optuna: A next-generation hyperparameter optimization framework," in *Proc. 25th ACM SIGKDD Int. Conf. on Knowledge Discovery and Data Mining*, 2019, pp. 2623–2631, doi: <https://doi.org/10.1145/3292500.3330701>.
- [25] C. J. Clopper and E. S. Pearson, "The use of confidence or fiducial limits illustrated in the case of the binomial," *Biometrika*, vol. 26, no. 4, pp. 404–413, 1934, doi: <https://doi.org/10.1093/biomet/26.4.404>.