

Predicción Probabilística del Mundial de Fútbol FIFA 2026 mediante Gradient Boosting y Simulación Monte Carlo

David Deras

Curso de Especialización en Machine Learning

Facultad de Ingeniería y Arquitectura

Universidad de El Salvador

San Salvador, El Salvador

dc19019@ues.edu.sv

Resumen—Se presenta un sistema end-to-end para estimar la probabilidad de campeonato de cada una de las 48 selecciones que disputarán la Copa Mundial de la FIFA 2026 bajo el nuevo formato de 12 grupos. El pipeline integra fuentes heterogéneas (resultados internacionales 1872–2026, datos de eventos, *Expected Goals* de StatsBomb, valor de mercado de Transfermarkt y ranking FIFA) para construir siete características —incluyendo features de eventos calculadas estrictamente *as-of-date*— que alimentan cuatro modelos multiclase entrenados sobre la distribución natural de clases con decaimiento temporal exponencial. El modelo final, seleccionado por log-loss en un *hold-out* de validación, es una regresión logística multinomial que obtiene un Log-Loss de ,836 sobre el conjunto de prueba temporal, estadísticamente empatada con LightGBM (bootstrap pareado). Un estudio de ablación multi-semilla muestra que, más allá de la diferencia de ELO, ningún grupo de features aporta señal significativa. El motor Monte Carlo de 10,000 iteraciones implementa el bracket oficial 2026 (mejores terceros contra ganadores de grupo, con pools de procedencia por partido), localía condicionada a la sede real y marcadores Poisson condicionados al resultado sorteado. El sistema se valida out-of-time sobre el Mundial 2022 sin *leakage* ni en el modelo ni en las features, y se contrasta contra las probabilidades implícitas del mercado de apuestas, frente al cual sobrepondera al líder de ELO (España: 27,5 % vs 14,9 % del mercado) — divergencia que se reporta y discute como limitación.

Index Terms—Fútbol, predicción probabilística, XGBoost, Monte Carlo, ranking ELO, Mundial 2026, calibración de probabilidades.

I. INTRODUCCIÓN

La Copa Mundial de la FIFA 2026 estrena el mayor cambio estructural de su historia: 48 selecciones repartidas en 12 grupos de 4, de los cuales avanzan los dos primeros lugares más los ocho mejores terceros, totalizando 32 equipos en la fase eliminatoria. El torneo agrega una ronda adicional (*Round of 32*) y eleva el total de partidos a 104 [1]. Este cambio reglamentario invalida directamente los modelos calibrados sobre formatos de 32 equipos y motiva un rediseño del motor de simulación.

Este trabajo introduce un sistema reproducible para estimar la probabilidad de título de cada selección. Las contribuciones son: (i) un pipeline de datos automatizado que combina cuatro fuentes históricas y modernas; (ii) un benchmark de cuatro

clasificadores multiclase entrenados con *time decay* exponencial sobre la distribución natural de clases, con selección del modelo final en un *hold-out* de validación y significancia por bootstrap pareado; (iii) un motor Monte Carlo sobre el bracket oficial 2026, incluyendo la asignación de los ocho mejores terceros a sus pools de procedencia, desempates reglamentarios con sorteo, localía condicionada a la sede real y marcadores Poisson condicionados al resultado; (iv) una validación out-of-time sobre el Mundial 2022 sin *leakage* ni en el modelo ni en las features, más un contraste contra las probabilidades implícitas del mercado de apuestas. Una versión previa del sistema (v1) contenía dos defectos metodológicos — rebalanceo de clases que deformaba las probabilidades y un bracket eliminatorio no reglamentario — cuya corrección, verificada con bootstrap pareado, mejora el log-loss de test de ,855 a ,836; este artículo reporta el sistema corregido.

II. TRABAJO RELACIONADO

El árbol genético de la predicción futbolística parte del modelo Poisson de Maher [3] y de su refinamiento Dixon–Coles [4], que captura la correlación de marcadores bajos. El sistema de puntuación Elo [5] proporciona una métrica de fuerza relativa actualizable partido a partido, hoy estandarizada para selecciones nacionales. Trabajos más recientes combinan *Random Forest* con *ratings* de equipo para Mundiales y Eurocopas [6]. La popularización de XGBoost [7] y LightGBM [8] ha desplazado la frontera hacia modelos de *gradient boosting*, mientras que SHAP [9] permite interpretar sus predicciones. Para evaluar la calibración de probabilidades el estándar son el Log-Loss y el Brier score [10], complementados con calibración isotónica o de Platt [11], [12].

III. PIPELINE DE DATOS

Los datos crudos se descargan o cargan en `src/data/` y se materializan en `data/raw/`; la limpieza y la unión producen `data/processed/features.csv`. El pipeline integra cinco fuentes, resumidas en la Tabla I.

Fuente principal de resultados. El dataset de Mart Jüriso [13] disponible tanto en GitHub como en Kaggle [14]

Tabla I
FUENTES DE DATOS INTEGRADAS EN EL PIPELINE

Fuente	Contenido	Cobertura
martj42 [13], [14]	Resultados internacionales	1872–2026, $\approx 49\,000$ partidos
martj42 (eventos) [13]	Goleadores (min, penal), tandas y nombres históricos	47.6k goles; 677 tandas
FIFA Ranking [15]	Posición y puntos (+ <i>snapshot</i> 2026)	1993–2026, ≈ 210 selecc.
StatsBomb [16]	xG por equipo	109 selecc.
Transfermarkt [17]	Valor de mercado plantilla	62 selecc., <i>snapshot</i>

constituye el núcleo del entrenamiento con $\approx 49,000$ partidos internacionales (1872–2026); según su documentación, los datos se recopilan de Wikipedia, RSSSF y los sitios web de las federaciones nacionales. De la misma colección provienen los archivos de eventos *goalscorers* (goleadores con minuto y penal) y *former_names* (continuidad de federaciones), usados para las features derivadas y la unificación de nombres (el archivo de tandas *shootouts* se carga pero su feature se retiró del modelo en v2). El ranking FIFA histórico [15] –serie 1993–2024 extendida con un *snapshot* manual del 2026-05-30– alimenta el feature *ranking_diff*.

Estadísticas avanzadas y valor de plantilla. Los xG históricos provienen del *open data* de StatsBomb [16], consumido vía *statsbombpy*; las selecciones sin cobertura StatsBomb reciben la media global ($\approx 1,2$) como imputación. El ELO se calcula *in-house* con la fórmula de Elo [5] sobre el historial completo de resultados, sin depender de un proveedor externo. El valor de mercado de las plantillas se obtiene con un *snapshot* manual de Transfermarkt [17].

Limpieza y unión. El proceso incluye: estandarización de nombres de países a un *canonical name* (USA $\rightarrow$ *United States*) y unificación de federaciones sucesoras reconocidas por FIFA (Yugoslavia $\rightarrow$ *Serbia*, Checoslovaquia $\rightarrow$ *Chequia*) para dar continuidad al ELO; deduplicación por (date, home, away); geocodificación de sedes con *geopy* (distancia 0 cuando falla); *merge-asof backward* del ranking FIFA –extendido con el *snapshot* del 2026-05-30, libre de *leakage* pues todo partido solo ve *ranks* anteriores a su fecha– e imputación del xG con la media global ($\approx 1,2$) para selecc. sin cobertura StatsBomb. El ELO se acumula sobre el **universo completo** de partidos (todos los torneos, incl. amistosos, desde 1872), no sobre el subconjunto filtrado de filas a emitir.

Licencias de datos. Los xG provienen del *open data* de StatsBomb [16], empleado bajo su licencia de uso no comercial con atribución. El valor de mercado de Transfermarkt [17] es un *snapshot* manual utilizado exclusivamente con fines académicos, sin redistribución del dato original. Las demás fuentes (martj42 y el ranking FIFA) son datasets públicos de uso para investigación.

Tabla II
CARACTERÍSTICAS DEL MODELO Y SU JUSTIFICACIÓN

Feature	Justificación
<i>elo_diff</i>	ELO local – ELO visitante (historia completa, margen de victoria); métrica dinámica superior al ranking FIFA estático [5]
<i>squad_value_diff</i>	$\log(\text{val}_L) - \log(\text{val}_V)$; proxy de calidad de plantilla
<i>xg_avg_for</i>	xG prom. a favor: local – visitante; eficiencia ofensiva
<i>xg_avg_against</i>	xG prom. en contra: local – visitante; solidez defensiva
<i>ranking_diff</i>	$\text{rank}_V - \text{rank}_L$; ranking FIFA (refrescado al 2026)
<i>penalty_share_diff</i>	% goles de penal, local – visitante (as-of)
<i>striker_concentration_diff</i>	Herfindahl de goleadores en ventana de 4 años, local – visitante (as-of)

IV. INGENIERÍA DE CARACTERÍSTICAS

Se construyen siete características (Tabla II). Dos de ellas se derivan de datos de eventos (goleadores) y se calculan estrictamente *as-of-date* mediante *merge_asof*(*backward*, *allow_exact_matches=False*), de modo que cada partido solo observa eventos *anteriores* a su fecha (sin *leakage*). El índice de concentración de goleadores usa una **ventana móvil de 4 años**: la versión acumulada de por vida (*v1*) medía en la práctica la antigüedad del programa futbolístico del país, no la estructura del ataque vigente. Tres features de la *v1* se retiraron por aporte nulo o negativo validado por ablación: *travel_distance_diff* (83 % de ceros en entrenamiento pero 100 % poblada en inferencia — un *shift* de distribución *train/inferencia*), *shootout_winrate_diff* (casi constante tras el *shrinkage* bayesiano) y *late_goal_ratio_diff* (ruido neto). La Fig. 2 ilustra la dinámica del ELO en cinco selecciones representativas; la Fig. 4 muestra colinealidad alta entre *elo_diff* y *ranking_diff* ($r \approx 0,88$) — las features retiradas aparecen en la figura por completitud histórica.

ELO con margen de victoria. El ELO propio incorpora el multiplicador estándar por margen (1,5 si la diferencia es 2; $(11 + d)/8$ si $d \geq 3$). La ventaja de local en el *expected score* está implementada pero desactivada: un grid de validación (logística sobre *elo_diff*, entrenamiento 2010–2018, validación 2019–2020) muestra que el margen mejora el log-loss en todas las configuraciones mientras que la ventaja de local no valida (,8102 con HA= 0 vs ,8117 con HA= 100).

IV-A. Decaimiento temporal (sin rebalanceo de clases)

Cada partido contribuye al entrenamiento con un peso

$$W(t) = e^{-\lambda \Delta t}, \quad \lambda = 1 \times 10^{-3} \text{ días}^{-1}, \quad (1)$$

donde Δt son los días entre la fecha del partido y el horizonte de referencia. Los pesos se renormalizan por su media para que el aprendizaje permanezca a escala unitaria.




Figura 1. Distribución de `elo_diff` por clase de resultado (H/E/V). La separación monotónica entre las tres distribuciones respalda el poder predictivo del feature.




Figura 2. Evolución del rating ELO para cinco selecciones representativas a lo largo de cuatro décadas.

Por qué NO se rebalancean las clases. La `v1` multiplicaba además por el peso `balanced` de `sklearn` para “corregir” el desbalance natural $H \approx 47\%$, $E \approx 21\%$, $V \approx 32\%$ (Fig. 3). Rebalancear clases es una técnica para clasificación dura con clases raras; cuando el objetivo son *probabilidades calibradas* evaluadas con log-loss, deforma las posteriores alejándolas de las tasas base (los empates se sobreponderaban $\sim 1,6\times$, produciendo una sobrepredicción media de $+3,5$ puntos porcentuales en la clase empate). Eliminar el rebalanceo mejora el log-loss de test de todos los modelos; para el XGBoost con hiperparámetros fijos la mejora es de ,8547 a ,8443 y la sobrepredicción de empates desaparece. El desbalance de clases NO se “corrige” porque no es un defecto: es la distribución real del fenómeno que el modelo debe estimar.

V. MODELADO

El problema se formula como clasificación multiclase a nivel de partido $\{H, E, V\}$. Se entrenan tres familias: Regresión Logística multinomial (con `StandardScaler`), XGBoost (multi:softprob) y LightGBM. La búsqueda de hiperparámetros emplea Optuna [18] con 100 *trials* y `TimeSeriesSplit(n=5)` interno sobre el conjunto de entrenamiento, optimizando `neg_log_loss`. La Fig. 5 resume la importancia SHAP agregada (mean |SHAP|) del XGBoost y muestra que `elo_diff` domina la contribución por un orden de magnitud. La cautela interpretativa es obligada: `elo_diff` y `ranking_diff` son altamente colineales ($r \approx 0,88$) y SHAP reparte crédito de forma inestable entre features correlacionadas, de modo que el orden de las features menores




Figura 3. Distribución de la variable objetivo. El desbalance hacia la clase *Local* motiva la ponderación `class_weight=balanced`.

Tabla III
SPLIT TEMPORAL Y USO DE CADA CONJUNTO

Conjunto	Filtro	Uso
Train	<code>date < 2021-01-01</code>	LogReg, XGBoost, LightGBM
Val-cal	primer 70 % de 2021	Calibración Platt (sigmoid)
Val-sel	último 30 % de 2021	Selección del modelo final
Test	<code>date ≥ 2022-01-01</code>	Evaluación final

no soporta conclusiones; la cuantificación rigurosa de aportes se delega al estudio de ablación multi-semilla (§VII-A).

V-A. División temporal y selección del modelo

El split es estrictamente temporal (Tabla III). La franja de validación 2021 se subdivide a su vez 70/30: el primer 70 % (val-cal) ajusta la calibración Platt del XGBoost y el 30 % final (val-sel) decide el modelo final por log-loss. Esta subdivisión evita un sesgo sutil: comparar el modelo calibrado sobre los mismos datos donde se ajustó su sigmoide lo favorecería espuriamente. El conjunto de prueba no interviene en ninguna decisión. En la corrida reportada, val-sel selecciona la **regresión logística multinomial** como modelo final — un resultado coherente con la ablación (§VII-A): la señal útil es esencialmente lineal en `elo_diff`.

Recorte mínimo. El entrenamiento usa partidos con `date ≥ 2010`, aunque `features.csv` contiene datos desde 1993. Los features estáticos (xG, valor de plantilla, ranking moderno) no son representativos del fútbol pre-2010, y el time decay con $\lambda=,001$ ya reduce el peso de esos partidos a menos del 2 %. El ELO sigue calculándose sobre el histórico completo para mayor precisión.

Doble pipeline. Para validar el Mundial 2022 sin leakage se re-ejecuta el entrenamiento con `cutoff = 2022-01-01` y, de forma crucial, **sin las features anacrónicas** (xG y valor de plantilla, que son *snapshots* de ~ 2026): un modelo “pre-2022” cuyo vector de entrada contiene información observada en




Figura 4. Matriz de correlación de las características evaluadas (incluye, por completitud, las retiradas en v2). Se observa colinealidad alta entre `elo_diff` y `ranking_diff` ($r = 0,88$) y una anti-correlación de `striker_concentration_diff` con la fuerza ($\approx -0,37$): los equipos fuertes reparten más el goleo.




Figura 5. Resumen SHAP agregado (mean |SHAP|) del XGBoost. `elo_diff` domina la contribución, con `striker_concentration_diff` en segundo lugar y `ranking_diff` en tercero.

2026 no constituye una validación out-of-time honesta aunque el target sea limpio. El pipeline limpio usa solo `elo_diff`, `ranking_diff` y las dos features de eventos as-of-date.

VI. MOTOR DE SIMULACIÓN DEL TORNEO

El motor (`src/simulation/`) ejecuta $N=10,000$ realizaciones del torneo completo. El bracket eliminatorio se carga como `dato` (`wc2026_bracket.csv`), transcrito del calendario oficial FIFA [1], [2]: de los 16 partidos del *Round of 32*, 8 enfrentan ganadores de grupo contra los mejores terceros (cada partido con un *pool* oficial de grupos de procedencia), 4

enfrentan ganadores contra segundos y 4 cruzan segundos entre sí. La versión v1 de este trabajo usaba un bracket inventado con cuatro cruces tercero-vs-tercero — inexistentes en el reglamento — que garantizaba exactamente 4 terceros en octavos y endurecía el camino de los favoritos; su corrección cambia materialmente la progresión. Cada partido pasa por las siguientes etapas:

1. **Probabilidades simétricas con localía por sede.** Se promedia $P(i \text{ vs } j)$ con la inversión de $P(j \text{ vs } i)$ para eliminar el sesgo home/away del dataset, salvo cuando un anfitrión juega *en su propio país* según la sede del calendario (México en una sede de EE.UU. no recibe localía; la v1 no verificaba la sede).
2. **Marcador condicionado al outcome.** El *outcome* $\{H, E, V\}$ se sortea con las probabilidades del modelo y el marcador se muestrea de la distribución conjunta Poisson independiente (μ basado en xG) *condicionada* a ese outcome (truncada y renormalizada sobre la grilla 0–10). Esto reemplaza la reconciliación ad-hoc de la v1 ($g_i \leftarrow g_j + 1$), que distorsionaba la distribución de DG/GF justo donde deciden los desempates.
3. **Fase de grupos.** 12 grupos de 4; clasifican los dos primeros más los 8 mejores terceros. Desempates según reglamento: **puntos** $\rightarrow$ **DG** $\rightarrow$ **GF** $\rightarrow$ **enfrentamiento directo** $\rightarrow$ **sorteo** (con el RNG de la iteración; la v1 dejaba el orden de inserción, un sesgo determinista). El *fair play* no es simulable y se omite (aproximación documentada).

4. **Asignación de terceros.** Los 8 mejores terceros se asignan a los 8 slots del R32 mediante un *matching* exacto que respeta los pools oficiales de procedencia (la tabla FIFA de 495 combinaciones es una elección particular entre los matchings válidos; no está publicada en forma compacta).

5. **Eliminatorias.** *Round of 32* → *Round of 16* → Cuartos → Semifinales → Final, con la progresión de llaves y sedes del calendario oficial. Si hay empate tras los 90', la definición por penales se modela como Bernoulli(0,5).

Se contabilizan, por equipo, las veces que alcanza cada ronda y los intervalos de confianza al 95 % se calculan con el método binomial exacto de Clopper–Pearson [19] vía `scipy.stats.beta`. Las N iteraciones, independientes entre sí, se reparten en bloques fijos ejecutados en paralelo (`joblib`); cada bloque usa un *stream* RNG propio derivado de `SeedSequence(seed).spawn`, de modo que el resultado es **idéntico con cualquier número de workers** (reproducibilidad independiente del paralelismo).

VII. EVALUACIÓN

Se reportan Log-Loss y Brier score sobre el conjunto de prueba ($\text{date} \geq 2022$). Se evita `accuracy` por ser inadecuada para predicciones probabilísticas desbalanceadas [10].

Nota metodológica sobre el Brier. El valor reportado es el promedio de los tres scores binarios *one-vs-rest* (cada clase $\{H, E, V\}$ contra el resto), de modo que se sitúa en el rango $[0, 1]$ y no en la formulación multiclase de suma de diferencias cuadráticas (rango $[0, 2]$). Ambas medidas son equivalentes salvo un factor: el Brier de suma multiclase es K veces el promediado, con $K = 3$ clases; así, el ,163 reportado corresponde a ,490 en la escala $[0, 2]$.

La Tabla IV reporta las métricas puntuales junto con el delta de log-loss frente al mejor modelo y su IC al 95 % por *bootstrap* pareado por partido (2,000 réplicas): los puntos sin intervalo no permiten afirmar que un modelo “gana”. LightGBM y la regresión logística quedan **estadísticamente empatados** en primer lugar; ambos superan significativamente al XGBoost. Como referencia, el baseline de priors de clase da 1,050 y el uniforme $\ln(3) = 1,099$; el mejor modelo de la v1 (con rebalanceo) daba ,8547.

La calibración Platt deja de ser necesaria. En la v1, la calibración “corregía la sobreconfianza” del XGBoost (,866 → ,855). El diagnóstico era incorrecto: lo que la sigmoide reparaba parcialmente era la deformación introducida por el propio rebalanceo de clases. Entrenando sobre la distribución natural, el XGBoost calibrado es *peor* que el crudo (,8716 vs ,8587): con un año de validación, la sigmoide añade varianza sin sesgo que corregir. La selección en val-sel resuelve esta decisión sin juicio manual.

VII-A. Estudio de ablación

Para cuantificar la contribución de cada grupo de features se reentrena el XGBoost calibrado con **diez semillas por configuración**, manteniendo fijos el split, los pesos y los

Tabla IV
EVALUACIÓN SOBRE TEST TEMPORAL (≥ 2022 , $n=2,208$). ΔLL VS MEJOR CON IC95 BOOTSTRAP PAREADO.

Modelo	Log-Loss ↓	Brier ↓	ΔLL [IC95]
LightGBM	,8356	,1634	—
LogReg	,8360	,1635	+ ,000 [− ,007, + ,009]
XGBoost	,8587	,1678	+ ,023 [+ ,015, + ,031]*
XGBoost-Cal	,8716	,1699	+ ,036 [+ ,026, + ,046]*

* significativo (el IC95 excluye el cero).




Figura 6. Curvas de calibración por clase. Todos los modelos se aproximan bien a la diagonal en *Away Win* y *Home Win*; la clase *Draw* queda sub-calibrada en todos — reflejo directo de la baja correlación entre features y empates ($|r| < 0,07$).

Tabla V
ABLACIÓN MULTI-SEMILLA (XGBOOST CALIBRADO, 10 SEEDS, TEST ≥ 2022). ΔLL VS COMPLETO CON IC95 BOOTSTRAP PAREADO.

Configuración	LL (media $\pm$ sd)	ΔLL [IC95]	Signif.
Completo (7 feat.)	,8675 $\pm$,0015	—	—
Sin xG	,8667 $\pm$,0017	− ,001 [− ,006, + ,005]	no
Sin <code>squad_value</code>	,8689 $\pm$,0020	+ ,002 [− ,001, + ,004]	no
Sin derivadas	,8623 $\pm$,0013	− ,005 [− ,011, + ,001]	no
Sin <code>penalty_share</code>	,8639 $\pm$,0016	− ,004 [− ,007, + ,000]	no
Sin estáticas (xG+squad)	,8656 $\pm$,0014	− ,002 [− ,007, + ,004]	no
Solo <code>elo_diff</code>	,8566 $\pm$,0007	− ,011 [− ,020, − ,002]	sí

hiperparámetros; se reporta media $\pm$ desviación del log-loss y un *bootstrap* pareado (por partido, sobre la pérdida promediada entre semillas) del delta frente al modelo completo. La v1 reportaba corridas únicas y concluía que las features estáticas y las derivadas “aportaban” +0,004; con repeticiones y un IC, esa conclusión no sobrevive. La Tabla V muestra el resultado, incisivo: **ningún grupo de features añade señal significativa sobre el resto, y la configuración de una sola feature (`elo_diff`) es significativamente MEJOR que el modelo completo** ($\Delta\text{LL} = -0,011$, IC95 $[-0,020, -0,002]$). En esta arquitectura y con este volumen de datos, las seis features adicionales introducen más varianza que señal. Este hallazgo es coherente con la selección del modelo final (una logística, esencialmente lineal en `elo_diff`) y reencuadra el papel del resto del pipeline: las features adicionales se conservan como instrumentación documentada, no como fuentes demostradas de señal.

Validación histórica (sin leakage). El pipeline `_pre2022` — entrenado solo con `date < 2022-01-01` y sin las features anacrónicas — se evalúa sobre los partidos de 2022 como prueba *out-of-time* en la que ni el modelo ni el vector de entrada ven información posterior al cutoff: log-loss 0,985,

Tabla VI

TOP-10 CANDIDATOS A CAMPEÓN (10 000 ITERACIONES, IC CLOPPER-PEARSON DE SIMULACIÓN) Y MERCADO DES-VIGORIZADO

Equipo	P(Campeón)	IC 95 % sim.	Mercado
España	27,46 %	[26,59, 28,35]	14,9 %
Argentina	13,78 %	[13,11, 14,47]	8,2 %
Francia	11,65 %	[11,03, 12,29]	13,7 %
Inglaterra	7,73 %	[7,21, 8,27]	10,2 %
Alemania	3,61 %	[3,25, 3,99]	5,5 %
Países Bajos	3,05 %	[2,72, 3,41]	3,9 %
Ecuador	3,05 %	[2,72, 3,41]	0,5 %
Brasil	3,04 %	[2,71, 3,40]	9,1 %
Colombia	3,00 %	[2,67, 3,35]	2,0 %
Japón	2,99 %	[2,66, 3,34]	1,6 %

Tabla VII

PROGRESIÓN POR FASE DE LOS ANFITRIONES (%)

Fase	México	EE.UU.	Canadá
Round of 32	96,3	74,7	97,2
Round of 16	61,5	44,5	61,9
Cuartos	28,4	21,0	30,1
Semifinales	11,3	7,8	10,1
Final	4,0	3,0	3,8
Campeón	1,2	1,0	1,2

accuracy 54,4 %. La cifra es peor que la del test principal — exactamente lo esperable al retirar el leakage de los snapshots, y la razón de reportarla: el test principal, que sí recibe los snapshots de 2026, debe leerse como **cota optimista**.

VIII. RESULTADOS DE LA SIMULACIÓN

La Tabla VI lista el Top-10 de candidatos al título junto a la probabilidad implícita del mercado, y la Tabla VII resume la progresión por fase de los tres anfitriones. **Semántica de los intervalos:** el IC de Clopper-Pearson cuantifica únicamente el error de muestreo Monte Carlo — reducible corriendo más iteraciones — y NO la incertidumbre del modelo. Para esta última, el modo `-ensemble` reentrena K réplicas *bootstrap* del modelo final y reporta el rango de P(campeón) entre réplicas (`simulation_ensemble.csv`), que es sustancialmente más ancho.

VIII-A. Benchmark contra el mercado de apuestas

Siguiendo la práctica estándar de la literatura [4], las probabilidades del modelo se contrastan con las implícitas del mercado (BetMGM, snapshot 2026-06-10, des-vigorizado por normalización proporcional; *overround* 1,22). La distancia de variación total entre ambas distribuciones es 0,27. El patrón de divergencia es sistemático: el modelo **sobrepondera al líder de ELO** (España 27,5 % vs 14,9 %; Argentina 13,8 % vs 8,2 %) e **infrapondera a equipos cuya calidad percibida excede su ELO reciente** (Brasil 3,0 % vs 9,1 %; Portugal 2,7 % vs 8,2 %). La causa es estructural: la señal del modelo es esencialmente `elo_diff` amplificada sobre siete rondas

Tabla VIII

SENSIBILIDAD AL ESCENARIO CONJUNTO DE LESIONES (SQUAD -30 %, xG -10 %, ELO -25)

Equipo	Base %	Lesión %	Δ pp
España	27,46	22,19	-5,27
Argentina	13,78	9,52	-4,26
Francia	11,65	9,26	-2,39
Inglaterra	7,73	6,01	-1,72
Alemania	3,61	2,46	-1,15

de torneo, sin *shrinkage* hacia el consenso ni información de plantillas que el mercado sí incorpora. Se reporta como limitación abierta en lugar de ajustar el modelo hacia el mercado ex-post.

VIII-B. Análisis de sensibilidad a lesiones

Las lesiones no se modelan estructuralmente; `src/analysis/sensitivity.py` aplica un escenario de crisis agregado al top-5 y re-ejecuta la simulación. La *v1* perturbaba únicamente `squad_value` (-30 %) — la feature de *menor* importancia del modelo — por lo que su resultado ($|\Delta| \leq 0,4$ pp) estaba predeterminado por el diseño. El escenario *v2* perturba conjuntamente los tres canales por los que una crisis de lesiones se manifiesta en el espacio de features: `squad_value` -30 %, `xg_for` -10 % y ELO -25 puntos. La Tabla VIII muestra efectos ahora materiales y monotónicos con la probabilidad base.

VIII-C. Incertidumbre del modelo (ensemble bootstrap)

Reentrenando $K=5$ réplicas *bootstrap* del modelo final y simulando 2,000 iteraciones con cada una, el rango de P(campeón) entre réplicas resulta mucho más ancho que el IC de simulación: para España, [23,6, 29,9] entre modelos frente a [26,1, 27,8] de Clopper-Pearson. La incertidumbre dominante del pronóstico es la del modelo, no la del Monte Carlo — razón por la que reportar únicamente intervalos de simulación (como la *v1*) transmite una precisión espuria.

IX. LIMITACIONES

El modelo presenta seis limitaciones reconocidas:

1. **Debutantes.** Equipos como Uzbekistán, Curazao o Cabo Verde tienen historial internacional escaso; su ELO se inicializa con el valor neutro 1500 y converge lentamente, lo que probablemente *infla* su probabilidad relativa frente a rivales subestimados de la misma confederación.
2. **Cobertura xG.** El *open data* de StatsBomb [16] privilegia torneos UEFA/CONMEBOL; 13 de las 48 selecciones reciben el xG por defecto de 1,2 (media global), lo que subestima la varianza inter-equipos fuera de Europa.
3. **Features estáticas anacrónicas en el pipeline principal.** El xG y el valor de plantilla son *snapshots* de ~ 2026 aplicados a todos los partidos, *incluido el test*: las métricas del test principal son por tanto una cota optimista. La cifra de referencia limpia es la validación WC2022 del pipeline `_pre2022`, que las excluye. A diferencia de

lo afirmado en la v1, Sí existe serie histórica de valores de Transfermarkt; versionarla es trabajo futuro.

4. **Concentración de señal y divergencia con el mercado.** La señal útil es esencialmente `elo_diff` (la ablación multi-semilla no encuentra aporte significativo de ningún otro grupo), y su amplificación sobre siete rondas produce favoritos más extremos que el mercado de apuestas (§VIII-A), sin *shrinkage* hacia el consenso.
5. **Asignación de terceros aproximada.** El matching de terceros respeta los pools oficiales por partido, pero la tabla FIFA exacta de 495 combinaciones no está publicada en forma compacta; entre matchings válidos se elige el primero en orden determinista. El *fair play* tampoco se simula como criterio de desempate.
6. **Lesiones de última hora.** No hay modelado estructural de bajas individuales; `sensitivity.py` es un *stress test* agregado (`squad -30 %`, `xG -10 %`, `ELO -25`). Una baja clave en una posición específica (e.g., portero titular) tiene un impacto que el modelo no puede capturar.

X. REPRODUCIBILIDAD

El repositorio mantiene una arquitectura modular bajo `src/` (`data/`, `features/`, `models/`, `simulation/`, `analysis/`, `visualization/`). Los CSVs versionables se producen en `data/processed/` y las figuras en `reports/figures/`. Toda la cadena se reproduce con:

```
pip install -e .
make all      # features -> train -> evaluate
              # -> simulate -> sensitivity
python -m src.analysis.ablation --seeds 10
python -m src.simulation.simulate \
    --iterations 10000 --ensemble 5
python -m src.analysis.benchmark
streamlit run \
    src/visualization/dashboard.py
```

La cobertura de pruebas (`pytest tests/ -v`, 57 tests) valida la mecánica del ELO (margen de victoria, ventaja de local condicionada a sede neutral), la estructura oficial del bracket (sin cruces tercero-vs-tercero, pools respetados), el matching de terceros sobre combinaciones muestreadas, la coherencia del Poisson condicionado con el outcome sorteado, los desempates por sorteo vía RNG y el cálculo *as-of-date* de las features de eventos. Los resultados de la v1 quedan congelados en `data/processed/baseline_v1/` y cualquier cambio se acepta solo con un delta de log-loss significativo según `src/analysis/compare_runs.py` (bootstrap pareado).

XI. CONCLUSIONES Y TRABAJO FUTURO

Se ha presentado un sistema reproducible para predecir la Copa Mundial 2026: múltiples fuentes limpias, siete características –dos de eventos, calculadas *as-of-date*–, *benchmark* de cuatro modelos con selección en validación y significancia por bootstrap pareado, un motor Monte Carlo de 10,000 iteraciones sobre el bracket oficial, validación out-of-time sin leakage y contraste con el mercado. El modelo final —

una regresión logística multinomial — logra Log-Loss de ,836 en test, estadísticamente empatada con LightGBM y significativamente mejor que el sistema v1 (,855; $\Delta = -0,019$, IC95 $[-0,030, -0,009]$).

El hallazgo metodológico central de esta revisión es deflacionario y, creemos, más valioso que un ranking de features: con repeticiones e intervalos, **ninguna feature más allá de `elo_diff` aporta señal demostrable** en este volumen de datos, y dos prácticas habituales — el rebalanceo de clases y la calibración aplicada sin diagnóstico del sesgo subyacente — degradaban activamente las probabilidades. Las simulaciones ubican a España (27,5 %), Argentina (13,8 %) y Francia (11,7 %) como favoritas, con la advertencia explícita de que el modelo es más extremo que el mercado en sus favoritos y de que la incertidumbre dominante es la del modelo (rango ensemble de España: [23,6, 29,9]), no la del Monte Carlo.

Trabajo futuro: (i) incorporar un modelo Dixon–Coles [4] para los marcadores en lugar de Poisson independiente condicionado; (ii) versionar por temporada el valor de plantilla (la serie histórica de Transfermarkt existe) y reconstruir el test principal sin anacronismo; (iii) *shrinkage* de las probabilidades hacia el consenso del mercado como modelo híbrido, evaluado fuera de muestra; y (iv) modelar lesiones a nivel de jugador integrando *features* de minutos disputados y posición.

DISPONIBILIDAD DE CÓDIGO Y RECURSOS

El código fuente, los scripts de entrenamiento, los datos procesados y los experimentos necesarios para reproducir los resultados de este estudio se encuentran disponibles públicamente en [20]. Asimismo, se proporciona un dashboard interactivo para la exploración de resultados y simulaciones mediante [21].

REFERENCIAS

- [1] Fédération Internationale de Football Association, “FIFA World Cup 2026 competition format and regulations,” 2023. [Online]. Available: <https://www.fifa.com/fifaplus/en/tournaments/mens/worldcup/canadamexicousa2026> (accessed 2026-05-31).
- [2] Wikipedia, “2026 FIFA World Cup knockout stage,” 2026. [Online]. Available: https://en.wikipedia.org/wiki/2026_FIFA_World_Cup_knockout_stage (accessed 2026-06-10). Calendario oficial de partidos 73–104 con sedes y pools de terceros, transcrito en `data/raw/wc2026_bracket.csv`.
- [3] M. J. Maher, “Modelling association football scores,” *Statistica Neerlandica*, vol. 36, no. 3, pp. 109–118, 1982, doi: <https://doi.org/10.1111/j.1467-9574.1982.tb00782.x>.
- [4] M. J. Dixon and S. G. Coles, “Modelling association football scores and inefficiencies in the football betting market,” *Journal of the Royal Statistical Society: Series C (Applied Statistics)*, vol. 46, no. 2, pp. 265–280, 1997, doi: <https://doi.org/10.1111/1467-9876.00065>.
- [5] A. E. Elo, *The Rating of Chessplayers, Past and Present*. New York: Arco Publishing, 1978.
- [6] A. Groll, C. Ley, G. Schaubberger, and H. Van Eetvelde, “A hybrid random forest to predict soccer matches in international tournaments,” *J. Quant. Anal. Sports*, vol. 15, no. 4, pp. 271–287, 2019, doi: <https://doi.org/10.1515/jqas-2018-0060>.
- [7] T. Chen and C. Guestrin, “XGBoost: A scalable tree boosting system,” in *Proc. 22nd ACM SIGKDD Int. Conf. on Knowledge Discovery and Data Mining*, 2016, pp. 785–794, doi: <https://doi.org/10.1145/2939672.2939785>.
- [8] G. Ke et al., “LightGBM: A highly efficient gradient boosting decision tree,” in *Adv. Neural Inf. Process. Syst. (NeurIPS)*, vol. 30, 2017.

- [9] S. M. Lundberg and S.-I. Lee, “A unified approach to interpreting model predictions,” in *Adv. Neural Inf. Process. Syst. (NeurIPS)*, vol. 30, 2017.
- [10] G. W. Brier, “Verification of forecasts expressed in terms of probability,” *Monthly Weather Review*, vol. 78, no. 1, pp. 1–3, 1950, doi: [https://doi.org/10.1175/1520-0493\(1950\)078<0001:VOFEIT>2.0.CO;2](https://doi.org/10.1175/1520-0493(1950)078<0001:VOFEIT>2.0.CO;2).
- [11] J. C. Platt, “Probabilistic outputs for support vector machines and comparisons to regularized likelihood methods,” in *Advances in Large Margin Classifiers*, 1999, pp. 61–74.
- [12] A. Niculescu-Mizil and R. Caruana, “Predicting good probabilities with supervised learning,” in *Proc. 22nd Int. Conf. on Machine Learning (ICML)*, 2005, pp. 625–632, doi: <https://doi.org/10.1145/1102351.1102430>.
- [13] M. Jürisoo, “International football results from 1872 to 2026 (results, goalscorers, shootouts, former_names),” GitHub repository, 2026. [Online]. Available: https://github.com/martj42/international_results (accessed 2026-05-31).
- [14] M. Jürisoo, “International football results from 1872 to 2017,” *Kaggle*, 2026. Según su documentación, datos recopilados de Wikipedia, RSSSF (rsssf.com) y los sitios web de las federaciones nacionales. [Online]. Available: <https://www.kaggle.com/datasets/martj42/international-football-results-from-1872-to-2017> (accessed 2026-05-31).
- [15] cashncarry, “FIFA world ranking 1993–2023,” *Kaggle*, 2023. [Online]. Available: <https://www.kaggle.com/datasets/cashncarry/fifaworldranking> (accessed 2026-05-31).
- [16] StatsBomb, “StatsBomb open data,” 2024. [Online]. Available: <https://github.com/statsbomb/open-data> (accessed 2026-05-31).
- [17] Transfermarkt, “National teams market values,” 2026, manual snapshot. [Online]. Available: <https://www.transfermarkt.com> (accessed 2026-05-31).
- [18] T. Akiba, S. Sano, T. Yanase, T. Ohta, and M. Koyama, “Optuna: A next-generation hyperparameter optimization framework,” in *Proc. 25th ACM SIGKDD Int. Conf. on Knowledge Discovery and Data Mining*, 2019, pp. 2623–2631, doi: <https://doi.org/10.1145/3292500.3330701>.
- [19] C. J. Clopper and E. S. Pearson, “The use of confidence or fiducial limits illustrated in the case of the binomial,” *Biometrika*, vol. 26, no. 4, pp. 404–413, 1934, doi: <https://doi.org/10.1093/biomet/26.4.404>.
- [20] D. Deras, “Predictions - World Cup 2026,” GitHub repository. [Online]. Available: <https://github.com/daiv05/fifa-world-cup-model>. Accessed: May 31, 2026.
- [21] D. Deras, “Predictions - World Cup 2026,” Streamlit application. [Online]. Available: <https://fifa-world-cup-model.streamlit.app/>