

# Predicción Probabilística del Mundial de Fútbol FIFA 2026 mediante Gradient Boosting y Simulación Monte Carlo

David Deras

Curso de Especialización en Machine Learning

Repositorio: [github.com/daiv05/fifa-world-cup-model](https://github.com/daiv05/fifa-world-cup-model)

dc19019@ues.edu.sv

**Resumen**—Se presenta un sistema end-to-end para estimar la probabilidad de campeonato de cada una de las 48 selecciones que disputarán la Copa Mundial de la FIFA 2026 bajo el nuevo formato de 12 grupos. El pipeline integra fuentes heterogéneas (resultados internacionales 1872–2026, datos de eventos –goleadores y tandas de penales–, *Expected Goals* de StatsBomb, valor de mercado de Transfermarkt y ranking FIFA histórico extendido con un *snapshot* de 2026) para construir nueve características –incluyendo features derivadas calculadas estrictamente *as-of-date*– que alimentan cuatro modelos multiclasa (Regresión Logística, XGBoost, LightGBM y XGBoost calibrado con Platt) entrenados con ponderación por decaimiento temporal exponencial y rebalanceo de clases. El mejor modelo (XGBoost calibrado con método Platt) obtiene un Log-Loss de 0,855 y un Brier de 0,166 sobre un conjunto de prueba temporal y se acopla a un motor Monte Carlo de 10,000 iteraciones que respeta el reglamento 2026 (2 primeros de grupo + 8 mejores terceros, desempates puntos→DG→GF, definición por penales). Los intervalos de confianza de Clopper–Pearson sitúan a un grupo reducido de selecciones históricamente fuertes entre los favoritos. Una sección dedicada discute las limitaciones del modelo: equipos debutantes sin historial, cobertura parcial de xG y ausencia de modelado estructural de lesiones.

**Index Terms**—Fútbol, predicción probabilística, XGBoost, Monte Carlo, ranking ELO, Mundial 2026, calibración de probabilidades.

## I. INTRODUCCIÓN

La Copa Mundial de la FIFA 2026 estrena el mayor cambio estructural de su historia: 48 selecciones repartidas en 12 grupos de 4, de los cuales avanzan los dos primeros lugares más los ocho mejores terceros, totalizando 32 equipos en la fase eliminatoria. El torneo agrega una ronda adicional (*Round of 32*) y eleva el total de partidos a 104 [1]. Este cambio reglamentario invalida directamente los modelos calibrados sobre formatos de 32 equipos y motiva un rediseño del motor de simulación.

Este trabajo introduce un sistema reproducible para estimar la probabilidad de título de cada selección. Las contribuciones son: (i) un pipeline de datos automatizado que combina cuatro fuentes históricas y modernas; (ii) un benchmark de tres clasificadores multiclasa entrenados con *time decay* exponencial y calibración de Platt (sigmoid) sobre un *hold-out* temporal; (iii) un motor Monte Carlo que implementa fielmente el reglamento 2026, incluyendo el desempate de los ocho mejores terceros y la simetría local/visitante con excepción para los anfitriones;

(iv) una validación histórica sobre el Mundial 2022 sin *data leakage* y un análisis de sensibilidad a lesiones (–30 % del valor de plantilla).

## II. TRABAJO RELACIONADO

El árbol genético de la predicción futbolística parte del modelo Poisson de Maher [2] y de su refinamiento Dixon–Coles [3], que captura la correlación de marcadores bajos. El sistema de puntuación Elo [4] proporciona una métrica de fuerza relativa actualizable partido a partido, hoy estandarizada para selecciones nacionales. Trabajos más recientes combinan *Random Forest* con *ratings* de equipo para Mundiales y Eurocopas [5]. La popularización de XGBoost [6] y LightGBM [7] ha desplazado la frontera hacia modelos de *gradient boosting*, mientras que SHAP [8] permite interpretar sus predicciones. Para evaluar la calibración de probabilidades el estándar son el Log-Loss y el Brier score [9], complementados con calibración isotónica o de Platt [10], [11].

## III. PIPELINE DE DATOS

Los datos crudos se descargan o cargan en `src/data/` y se materializan en `data/raw/`; la limpieza y la unión producen `data/processed/features.csv`. El pipeline integra tres categorías de fuentes (datasets históricos, APIs y scraping), resumidas en la Tabla I.

**Fuente principal de resultados.** El dataset de Mart Jürisoo [12] disponible tanto en GitHub como en Kaggle [13] constituye el núcleo del entrenamiento con  $\approx 49,000$  partidos internacionales (1872–2026). Se complementa con los resultados de Mundiales 1974–2022 [15] y los datos estructurados de openfootball [17] para validar el formato del torneo. El ranking FIFA histórico [14] y el dataset de probabilidades base WC 2026 basado en Elo [16] se usan como referencia cruzada para calibrar el feature `ranking_diff`.

**Fuentes de estadísticas avanzadas.** Los xG históricos provienen del *open data* de StatsBomb [18], consumido vía `statsbombpy`. Para selecciones con escasa cobertura StatsBomb se consultan FBref [21] (xA, presiones, progresiones de pase) y API-Football [19] (estadísticas de jugadores en ligas europeas). Football-Data.org [20] complementa el seguimiento de los convocados en ligas domésticas. Los ratings Elo se contrastan con EloRatings.net [23], cuyo sistema dinámico es

Tabla I  
FUENTES DE DATOS INTEGRADAS EN EL PIPELINE

| Fuente                           | Contenido                                  | Cobertura                             |
|----------------------------------|--------------------------------------------|---------------------------------------|
| <i>Datasets históricos</i>       |                                            |                                       |
| martj42 [12], [13]               | Resultados internacionales                 | 1872–2026, $\approx 49\,000$ partidos |
| martj42 (eventos) [12]           | Goleadores (min, penal) y tandas           | 47.6k goles; 677 tandas               |
| FIFA Ranking [14]                | Posición y puntos (+ <i>snapshot</i> 2026) | 1993–2026, $\approx 210$ selecc.      |
| WC Matches [15]                  | Partidos Mundiales                         | 1974–2022                             |
| WC 2026 Base-line [16]           | Prob. base Elo WC 2026                     | 48 equipos, fase grupos               |
| openfootball [17]                | Fixtures y resultados WC                   | Todas las ediciones                   |
| StatsBomb [18]                   | xG por equipo                              | 109 selecc.                           |
| <i>APIs (datos actualizados)</i> |                                            |                                       |
| API-Football [19]                | Estadísticas de jugadores, xG              | Ligas europeas                        |
| Football-Data.org [20]           | Ligas domésticas de convocados             | Europa y América                      |
| <i>Web scraping</i>              |                                            |                                       |
| FBref [21]                       | xA, presiones, progresiones                | Internac. y ligas                     |
| Transfermarkt [22]               | Valor de mercado plantilla                 | 60 selecc., snapshot                  |
| EloRatings.net [23]              | ELO histórico verificado                   | $\approx 200$ selecc.                 |

considerado más preciso que el ranking FIFA estático. El valor de mercado de las plantillas se obtiene con un *snapshot* manual de Transfermarkt [22].

**Limpieza y unión.** El proceso incluye: estandarización de nombres de países a un *canonical name* (USA→*United States*) y unificación de federaciones sucesoras reconocidas por FIFA (Yugoslavia→*Serbia*, Checoslovaquia→*Chequia*) para dar continuidad al ELO; deduplicación por (date, home, away); geocodificación de sedes con geopy (distancia 0 cuando falla); *merge-asof backward* del ranking FIFA – extendido con el *snapshot* del 2026-05-30, libre de *leakage* pues todo partido solo ve *ranks* anteriores a su fecha– e imputación del xG con la media global ( $\approx 1,2$ ) para selecc. sin cobertura StatsBomb. El ELO se acumula sobre el **universo completo** de partidos (todos los torneos, incl. amistosos, desde 1872), no sobre el subconjunto filtrado de filas a emitir.

**Licencias de datos.** Los xG provienen del *open data* de StatsBomb [18], empleado bajo su licencia de uso no comercial con atribución. El valor de mercado de Transfermarkt [22] es un *snapshot* manual utilizado exclusivamente con fines académicos, sin redistribución del dato original. El resto de fuentes son datasets públicos o APIs con planes gratuitos para investigación.

Tabla II  
CARACTERÍSTICAS DEL MODELO Y SU JUSTIFICACIÓN

| Feature                    | Justificación                                                                                                   |
|----------------------------|-----------------------------------------------------------------------------------------------------------------|
| elo_diff                   | ELO local – ELO visitante (ELO sobre historia completa); métrica dinámica superior al ranking FIFA estático [4] |
| squad_value_diff           | $\log(\text{val}_L) - \log(\text{val}_V)$ ; proxy de calidad de plantilla                                       |
| xg_avg_for                 | xG prom. a favor: local – visitante; eficiencia ofensiva                                                        |
| xg_avg_against             | xG prom. en contra: local – visitante; solidez defensiva                                                        |
| travel_distance_diff       | dist. visitante–local a la sede (km); fatiga de viaje (no se anula en sede neutral)                             |
| ranking_diff               | $\text{rank}_V - \text{rank}_L$ ; ranking FIFA (refrescado al 2026)                                             |
| penalty_share_diff         | % goles de penal, local – visitante (as-of)                                                                     |
| striker_concentration_diff | Herfindahl de goleadores, local – visitante (as-of); dependencia de una figura                                  |
| shootout_winrate_diff      | winrate en tandas (Bayes, prior 0,5), local – visitante (as-of)                                                 |




Figura 1. Distribución de *elo\_diff* por clase de resultado (H/E/V). La separación monotónica entre las tres distribuciones respalda el poder predictivo del feature.

#### IV. INGENIERÍA DE CARACTERÍSTICAS

Se construyen nueve características justificadas tanto teóricamente como mediante EDA (Tabla II). Tres de ellas se derivan de datos de eventos (goleadores y tandas) y se calculan estrictamente *as-of-date* mediante *merge\_asof* (backward, allow\_exact\_matches=False), de modo que cada partido solo observa eventos *anteriores* a su fecha (sin *leakage*). La Fig. 2 ilustra la dinámica del ELO en cinco selecciones representativas; la Fig. 4 muestra colinealidad alta entre *elo\_diff* y *ranking\_diff* ( $r \approx 0,88$ ), mientras que el resto de pares se mantiene en niveles moderados.

##### IV-A. Decaimiento temporal y ponderación de clases

Cada partido contribuye al entrenamiento con un peso

$$W(t) = e^{-\lambda \Delta t} \cdot c_{y_i}, \quad \lambda = 1 \times 10^{-3} \text{ días}^{-1}, \quad (1)$$

donde  $\Delta t$  son los días entre la fecha del partido y la más reciente del dataset, y  $c_{y_i}$  es el peso *balanced* de *sklearn* sobre la etiqueta  $y_i \in \{H, E, V\}$ . Esto corrige el desbalance natural  $H \approx 49\%$ ,  $E \approx 21\%$ ,  $V \approx 30\%$  (Fig. 3) y prioriza la




Figura 2. Evolución del rating ELO para cinco selecciones representativas a lo largo de cuatro décadas.




Figura 3. Distribución de la variable objetivo. El desbalance hacia la clase *Local* motiva la ponderación `class_weight=balanced`.

señal reciente. Los pesos se renormalizan por su media para que el aprendizaje permanezca a escala unitaria.

## V. MODELADO

El problema se formula como clasificación multiclase a nivel de partido  $\{H, E, V\}$ . Se entrenan tres modelos: Regresión Logística multinomial (*baseline*, con `StandardScaler`), XGBoost (`multi:softprob`) y LightGBM. La búsqueda de hiperparámetros emplea Optuna [24] con 100 *trials* y `TimeSeriesSplit(n=5)` interno sobre el conjunto de entrenamiento, optimizando `neg_log_loss`. La búsqueda admite paralelización opcional de *trials* (`-n-jobs`), con valor por defecto en serie para garantizar reproducibilidad bit a bit del TPE. La Fig. 5 resume la importancia SHAP agregada (mean |SHAP|) y muestra que `elo_diff` domina ( $\approx 1.48$ ), seguido –de forma notable– por `striker_concentration_diff` ( $\approx 0.36$ ) y `ranking_diff` ( $\approx 0.25$ ). La concentración de goleadores, derivada de los datos de eventos, captura un eje (estructura del ataque) ortogonal al nivel del equipo. Las features de `xG` y `penalty_share_diff` forman un tercer nivel ( $\approx 0.10$ – $0.12$ ), mientras que `shootout_winrate_diff` ( $\approx 0.09$ ), `squad_value_diff` ( $\approx 0.04$ ) y

Tabla III  
SPLIT TEMPORAL Y USO DE CADA CONJUNTO

| Conjunto   | Filtro                                         | Uso                         |
|------------|------------------------------------------------|-----------------------------|
| Train      | <code>date &lt; 2021-01-01</code>              | LogReg, XGBoost, LightGBM   |
| Validación | <code>2021-01-01 ≤ date &lt; 2022-01-01</code> | Calibración Platt (sigmoid) |
| Test       | <code>date ≥ 2022-01-01</code>                 | Evaluación final            |

`travel_distance_diff` ( $\approx 0.03$ , coherente con su 82,5 % de ceros) aportan marginalmente.

### V-A. División temporal del dataset

Se evita rigurosamente el *data leakage* mediante un split estrictamente temporal (Tabla III). La calibración Platt (sigmoid) del XGBoost se ajusta sobre la franja 2021 (validación) para no contaminar el conjunto de prueba. El método sigmoid es más estable que el isotónico cuando el conjunto de validación es pequeño (un año de datos, tres clases), evitando sobreajuste en la curva de calibración.

**Recorte mínimo.** El entrenamiento usa partidos con `date ≥ 2010`, aunque `features.csv` contiene datos desde 1993. Los features estáticos (`xG`, valor de plantilla, ranking moderno) no son representativos del fútbol pre-2010, y el time decay con  $\lambda = 0.001$  ya reduce el peso de esos partidos a menos del 2 %. El ELO sigue calculándose sobre el histórico completo para mayor precisión.

**Doble pipeline.** Para validar el Mundial 2022 sin leakage se re-ejecuta el entrenamiento con `cutoff = 2022-01-01`, produciendo `xgboost_pre2022.joblib`. Cuando este `cutoff` vacía el conjunto de validación temporal, se activa un *fallback* 85/15 que reserva el último 15 % temporal del *train* para la calibración.

## VI. MOTOR DE SIMULACIÓN DEL TORNEO

El motor (`src/simulation/`) ejecuta  $N=10,000$  realizaciones del torneo completo (104 partidos  $\times N=1.04 \times 10^6$  partidos simulados). Cada partido  $i, j$  pasa por las siguientes etapas:

1. **Probabilidades simétricas.** Salvo cuando uno de los equipos es anfitrión jugando en su país, se promedia  $P(i \text{ vs } j)$  con la inversión de  $P(j \text{ vs } i)$  para eliminar el sesgo home/away heredado del dataset.
2. **Marcador y outcome.** El *outcome*  $\{H, E, V\}$  se sortea con las probabilidades del modelo. En fase de grupos se generan goles  $g_i \sim \text{Poisson}(\mu_i)$ ,  $g_j \sim \text{Poisson}(\mu_j)$  con  $\mu$  basado en `xG` a favor/en contra, y el marcador se ajusta para ser coherente con el outcome (desempates por DG/GF).
3. **Fase de grupos.** 12 grupos de 4; clasifican los dos primeros más los 8 mejores terceros, con desempates puntos  $\rightarrow$  diferencia de goles  $\rightarrow$  goles a favor según el reglamento FIFA 2026 [1].




Figura 4. Matriz de correlación de las nueve características. Se observa colinealidad alta entre `elo_diff` y `ranking_diff` ( $r = 0,88$ ) y una anti-correlación de `striker_concentration_diff` con la fuerza ( $\approx -0,37$ ): los equipos fuertes reparten más el goleo.




Figura 5. Resumen SHAP agregado (mean |SHAP|) del XGBoost. `elo_diff` domina la contribución, con `striker_concentration_diff` en segundo lugar y `ranking_diff` en tercero.

4. **Eliminatorias.** *Round of 32*  $\rightarrow$  *Round of 16*  $\rightarrow$  Cuartos  $\rightarrow$  Semifinales  $\rightarrow$  Final. Si hay empate tras los 90', la definición por penales se modela como Bernoulli(0,5).

Se contabilizan, por equipo, las veces que alcanza cada ronda y los intervalos de confianza al 95 % se calculan con el método binomial exacto de Clopper–Pearson [25] vía `scipy.stats.beta`. Las  $N$  iteraciones, independientes entre sí, se reparten en bloques fijos ejecutados en paralelo (`joblib`); cada bloque usa un *stream* RNG propio derivado de `SeedSequence(seed).spawn`, de modo que el resultado es **idéntico con cualquier número de workers**

(reproducibilidad independiente del paralelismo).

## VII. EVALUACIÓN

Se reportan Log-Loss y Brier score sobre el conjunto de prueba ( $\text{date} \geq 2022$ ). Se evita `accuracy` por ser inadecuada para predicciones probabilísticas desbalanceadas [9].

**Nota metodológica sobre el Brier.** El valor reportado es el promedio de los tres scores binarios *one-vs-rest* (cada clase  $\{H, E, V\}$  contra el resto), de modo que se sitúa en el rango  $[0, 1]$  y no en la formulación multiclase de suma de diferencias cuadráticas (rango  $[0, 2]$ ). Ambas medidas son equivalentes salvo un factor: el Brier de suma multiclase es  $K$  veces el promediado, con  $K = 3$  clases; así, el 0,166 reportado corresponde a 0,499 en la escala  $[0, 2]$ .

La Tabla IV muestra que XGBoost calibrado es el mejor modelo en ambas métricas — el único que supera a todos los demás simultáneamente en Log-Loss y Brier. La calibración Platt sobre datos de validación 2021 corrige la sobreconfianza del XGBoost base sin degradar su discriminación (Log-Loss  $0,866 \rightarrow 0,855$ ). El XGBoost sin calibrar supera a LightGBM, y LogReg queda en último lugar pese al rebalanceo de clases y el *time decay*.

### VII-A. Estudio de ablación

Para cuantificar la contribución marginal de cada grupo de features se reentrena el XGBoost calibrado manteniendo fijos el split temporal, los pesos (*time decay* + *balanced*) y los hiperparámetros óptimos; lo único que varía entre

Tabla IV  
MÉTRICAS DE EVALUACIÓN SOBRE TEST TEMPORAL ( $\geq 2022$ )

| Modelo      | Log-Loss ↓    | Brier ↓       |
|-------------|---------------|---------------|
| XGBoost-Cal | <b>0,8547</b> | <b>0,1662</b> |
| XGBoost     | 0,8657        | 0,1701        |
| LightGBM    | 0,8713        | 0,1717        |
| LogReg      | 0,8832        | 0,1728        |




Figura 6. Curvas de calibración por clase. Todos los modelos se aproximan bien a la diagonal en *Away Win* y *Home Win*; la clase *Draw* queda sub-calibrada en todos — reflejo directo de la baja correlación entre features y empates ( $|r| < 0,07$ ).

Tabla V  
ABLACIÓN DE FEATURES (XGBOOST CALIBRADO, TEST  $\geq 2022$ )

| Configuración            | Log-Loss | Brier  | $\Delta LL$ | $\Delta Brier$ |
|--------------------------|----------|--------|-------------|----------------|
| Completo (9 feat.)       | 0,8547   | 0,1662 | —           | —              |
| Sin xG                   | 0,8587   | 0,1670 | +0,0040     | +0,0008        |
| Sin squad_value          | 0,8553   | 0,1664 | +0,0006     | +0,0002        |
| Sin derivadas            | 0,8582   | 0,1668 | +0,0035     | +0,0006        |
| Sin travel_distance      | 0,8548   | 0,1663 | +0,0001     | +0,0001        |
| Sin penalty_share        | 0,8542   | 0,1661 | −0,0005     | −0,0001        |
| Sin shootout             | 0,8555   | 0,1664 | +0,0008     | +0,0002        |
| Sin estáticas (xG+squad) | 0,8588   | 0,1670 | +0,0041     | +0,0008        |

filas es el conjunto de features. La Tabla V muestra que el grupo de mayor aporte son las features estáticas (xG + valor de plantilla,  $\Delta LL = +0,0041$  al retirarlas) seguido de las features derivadas de eventos (+0,0035, impulsado sobre todo por *striker\_concentration\_diff*). Las features de aporte *marginal* (*travel\_distance\_diff*, *penalty\_share\_diff*, *shootout\_winrate\_diff*) se documentan con filas propias: sus  $\Delta$  caen dentro del ruido de una sola corrida ( $|\Delta LL| \leq 0,0008$ ). En particular, *penalty\_share\_diff* muestra un  $\Delta$  ligeramente negativo, indistinguible de cero. Una cuarta feature derivada evaluada (*late\_goal\_ratio*, proporción de goles tardíos) se descartó por completo del modelo: su ablación *leave-one-out* mostró aporte **negativo** (ruido neto, el modelo mejora sin ella).

**Validación histórica.** El modelo `xgboost_pre2022` (entrenado exclusivamente con `date < 2022-01-01`) se evaluó sobre los partidos del Mundial 2022, sirviendo como prueba *out-of-time* sin contaminación. Los resultados numéricos se imprimen en consola al ejecutar `make evaluate`.

Tabla VI  
TOP-10 CANDIDATOS A CAMPEÓN (10 000 ITERACIONES)

| Equipo       | P(Campeón) | IC 95 %        |
|--------------|------------|----------------|
| España       | 23,72 %    | [22,89, 24,57] |
| Argentina    | 11,27 %    | [10,66, 11,91] |
| Francia      | 10,88 %    | [10,28, 11,51] |
| Brasil       | 6,35 %     | [ 5,88, 6,85]  |
| Inglaterra   | 5,55 %     | [ 5,11, 6,02]  |
| Marruecos    | 4,51 %     | [ 4,11, 4,94]  |
| Alemania     | 4,18 %     | [ 3,80, 4,59]  |
| México       | 4,06 %     | [ 3,68, 4,47]  |
| Colombia     | 3,61 %     | [ 3,25, 3,99]  |
| Países Bajos | 3,48 %     | [ 3,13, 3,86]  |

Tabla VII  
PROGRESIÓN POR FASE DE LOS ANFITRIONES (% , IC 95 %)

| Fase        | México | EE.UU. | Canadá |
|-------------|--------|--------|--------|
| Round of 32 | 94,5   | 66,3   | 96,5   |
| Round of 16 | 63,3   | 30,3   | 53,6   |
| Cuartos     | 33,5   | 16,9   | 25,8   |
| Semifinales | 18,4   | 7,7    | 11,7   |
| Final       | 9,4    | 2,9    | 5,0    |
| Campeón     | 4,1    | 1,1    | 1,9    |

Tabla VIII  
SENSIBILIDAD A UNA REDUCCIÓN DEL 30 % EN EL VALOR DE PLANTILLA

| Equipo     | Base % | Lesión % | $\Delta$ pp |
|------------|--------|----------|-------------|
| España     | 23,72  | 23,38    | −0,34       |
| Argentina  | 11,27  | 10,87    | −0,40       |
| Francia    | 10,88  | 10,57    | −0,31       |
| Brasil     | 6,35   | 6,17     | −0,18       |
| Inglaterra | 5,55   | 5,34     | −0,21       |

## VIII. RESULTADOS DE LA SIMULACIÓN

La Tabla VI lista el Top-10 de candidatos al título y la Tabla VII resume la progresión por fase de los tres anfitriones, ambos con intervalos Clopper–Pearson al 95 %.

### VIII-A. Análisis de sensibilidad a lesiones

Aunque las lesiones no se modelan estructuralmente, el script `src/analysis/sensitivity.py` aplica una perturbación de −30 % sobre *squad\_value* para cada equipo del top-5 y re-ejecuta la simulación. La Tabla VIII muestra que el efecto es modesto ( $|\Delta| \leq 0,40$  pp en todos los casos), siempre en la dirección esperada (reducción de la probabilidad de título). Esto es coherente con la importancia SHAP: *squad\_value\_diff* ocupa una de las últimas posiciones (Fig. 5), muy por debajo de *elo\_diff* y de las features de estructura del ataque.

## IX. LIMITACIONES

El modelo presenta cinco limitaciones reconocidas:

1. **Debutantes.** Equipos como Uzbekistán, Curazao o Cabo Verde tienen historial internacional escaso; su ELO se

inicializa con el valor neutro 1500 y converge lentamente, lo que probablemente *infla* su probabilidad relativa frente a rivales subestimados de la misma confederación.

2. **Cobertura xG.** El *open data* de StatsBomb [18] privilegia torneos UEFA/CONMEBOL; las selecciones de AFC, CAF y CONCACAF reciben un xG por defecto de 1,2, que es la media global. Esto subestima la varianza inter-equipos en estas confederaciones.
3. **Features estáticas anacrónicas.** El xG y el valor de plantilla son *snapshots* (un valor por equipo, sin fecha) aplicados a todos los partidos históricos, lo que introduce un anacronismo/*leakage*. No existe serie temporal histórica de estos datos, así que versionarlos sería fabricar información; el efecto se acota con el *time decay* ( $< 2\%$  pre-2010), el recorte a *date*  $\geq 2010$  y el uso de *diffs* relativos, y se cuantifica en la fila “Sin estáticas” de la Tabla V. El valor de Transfermarkt es además una fotografía manual (no *live scraping*).
4. **Cobertura de *travel\_distance\_diff*.** Las coordenadas solo están precargadas para los 48 equipos del Mundial; los partidos históricos entre otros equipos quedan en 0 (82,5 % del dataset). La feature ya no se anula en sedes neutrales —corrige el caso de los Mundiales— y en la simulación (*host\_distance*) está 100 % poblada.
5. **Lesiones de última hora.** No hay modelado estructural de bajas individuales; el *sensitivity.py* es únicamente un *stress test* agregado sobre *squad\_value*. Una baja clave en una posición específica (e.g., portero titular) tiene un impacto que el modelo no puede capturar.

## X. REPRODUCIBILIDAD

El repositorio mantiene una arquitectura modular bajo `src/` (`data/`, `features/`, `models/`, `simulation/`, `analysis/`, `visualization/`), con CSVs versionables producidos en `data/processed/` y figuras en `reports/figures/`. Toda la cadena se reproduce con:

```
pip install -e .
make all      # features -> train -> evaluate
              # -> simulate -> sensitivity
streamlit run \
  src/visualization/dashboard.py
```

La cobertura de pruebas (`pytest tests/ -v`) valida la mecánica del ELO, la lógica de desempates de grupos y el muestreo Poisson de goles. Un *dashboard* Streamlit se publica en <https://fifa-world-cup-model.streamlit.app/>.

## XI. CONCLUSIONES Y TRABAJO FUTURO

Se ha presentado un sistema reproducible para predecir la Copa Mundial 2026 que cumple con los requisitos planteados: múltiples fuentes limpias, nueve características justificadas por EDA y SHAP —tres de ellas derivadas de datos de eventos y calculadas *as-of-date*—, *benchmark* de cuatro modelos con calibración Platt sobre validación temporal y

un motor Monte Carlo de 10,000 iteraciones fiel al nuevo reglamento. El XGBoost calibrado logra Log-Loss de 0,855 y Brier de 0,166 — mejor en ambas métricas simultáneamente. Más allá del núcleo *elo\_diff/ranking\_diff*, el hallazgo más relevante es que *striker\_concentration\_diff* (estructura del ataque) es la segunda feature más informativa. Las simulaciones ubican a España (23,7 %), Argentina (11,3 %) y Francia (10,9 %) como principales favoritas; los tres anfitriones alcanzan probabilidades de título entre 1,1 % y 4,1 %, con ventaja de local coherente en rondas iniciales pero convergencia en etapas avanzadas.

Trabajo futuro: (i) incorporar un modelo Dixon–Coles [3] para los marcadores en lugar de Poisson independiente; (ii) reemplazar el *snapshot* Transfermarkt por un *scraper* programado y versionar xG/valor de plantilla por temporada para eliminar el anacronismo; (iii) escalar a  $10^5 - 10^6$  iteraciones mediante vectorización completa del bucle Monte Carlo (ya paralelizado con *joblib*); y (iv) modelar lesiones a nivel de jugador integrando *features* de minutos disputados y posición.

## REFERENCIAS

- [1] Fédération Internationale de Football Association, “FIFA World Cup 2026 competition format and regulations,” 2023. [Online]. Available: <https://www.fifa.com/fifaplus/en/tournaments/mens/worldcup/canadamexicousa2026> (accessed 2026-05-24).
- [2] M. J. Maher, “Modelling association football scores,” *Statistica Neerlandica*, vol. 36, no. 3, pp. 109–118, 1982, doi: <https://doi.org/10.1111/j.1467-9574.1982.tb00782.x>.
- [3] M. J. Dixon and S. G. Coles, “Modelling association football scores and inefficiencies in the football betting market,” *Journal of the Royal Statistical Society: Series C (Applied Statistics)*, vol. 46, no. 2, pp. 265–280, 1997, doi: <https://doi.org/10.1111/1467-9876.00065>.
- [4] A. E. Elo, *The Rating of Chessplayers, Past and Present*. New York: Arco Publishing, 1978.
- [5] A. Groll, C. Ley, G. Schaubberger, and H. Van Eetvelde, “A hybrid random forest to predict soccer matches in international tournaments,” *J. Quant. Anal. Sports*, vol. 15, no. 4, pp. 271–287, 2019, doi: <https://doi.org/10.1515/jqas-2018-0060>.
- [6] T. Chen and C. Guestrin, “XGBoost: A scalable tree boosting system,” in *Proc. 22nd ACM SIGKDD Int. Conf. on Knowledge Discovery and Data Mining*, 2016, pp. 785–794, doi: <https://doi.org/10.1145/2939672.2939785>.
- [7] G. Ke et al., “LightGBM: A highly efficient gradient boosting decision tree,” in *Adv. Neural Inf. Process. Syst. (NeurIPS)*, vol. 30, 2017.
- [8] S. M. Lundberg and S.-I. Lee, “A unified approach to interpreting model predictions,” in *Adv. Neural Inf. Process. Syst. (NeurIPS)*, vol. 30, 2017.
- [9] G. W. Brier, “Verification of forecasts expressed in terms of probability,” *Monthly Weather Review*, vol. 78, no. 1, pp. 1–3, 1950, doi: [https://doi.org/10.1175/1520-0493\(1950\)078<0001:VOFEIT>2.0.CO;2](https://doi.org/10.1175/1520-0493(1950)078<0001:VOFEIT>2.0.CO;2).
- [10] J. C. Platt, “Probabilistic outputs for support vector machines and comparisons to regularized likelihood methods,” in *Advances in Large Margin Classifiers*, 1999, pp. 61–74.
- [11] A. Niculescu-Mizil and R. Caruana, “Predicting good probabilities with supervised learning,” in *Proc. 22nd Int. Conf. on Machine Learning (ICML)*, 2005, pp. 625–632, doi: <https://doi.org/10.1145/1102351.1102430>.
- [12] M. Jürisoo, “International football results from 1872 to 2024,” 2024. [Online]. Available: [https://github.com/martj42/international\\_results](https://github.com/martj42/international_results) (accessed 2026-05-24).
- [13] M. Jürisoo, “International football results from 1872 to 2024,” *Kaggle*, 2024. [Online]. Available: <https://www.kaggle.com/datasets/martj42/international-football-results-from-1872-to-2017> (accessed 2026-05-24).
- [14] cashncarry, “FIFA world ranking 1993–2023,” *Kaggle*, 2023. [Online]. Available: <https://www.kaggle.com/datasets/cashncarry/fifaworldranking> (accessed 2026-05-24).

- [15] I. Shahrukh, "FIFA world cup matches 1974–2022," *Kaggle*, 2023. [Online]. Available: <https://www.kaggle.com/datasets/ibrahimshahrukh/fifa-world-cup-matches-19742022-dataset> (accessed 2026-05-24).
- [16] S. Zahran, "WC2026 match probability baseline dataset," *Kaggle*, 2024. [Online]. Available: <https://www.kaggle.com/datasets/sarazahran1/wc2026-match-probability-baseline-dataset> (accessed 2026-05-24).
- [17] openfootball contributors, "World cup data repository," GitHub, 2024. [Online]. Available: <https://github.com/openfootball/worldcup> (accessed 2026-05-24).
- [18] StatsBomb, "StatsBomb open data," 2024. [Online]. Available: <https://github.com/statsbomb/open-data> (accessed 2026-05-24).
- [19] RapidAPI / API-Football, "API-Football: Football statistics and live scores," 2024. [Online]. Available: <https://rapidapi.com/collection/football-soccer> (accessed 2026-05-24).
- [20] Football-Data.org, "Football data and results," 2024. [Online]. Available: <https://www.football-data.org/> (accessed 2026-05-24).
- [21] Sports Reference LLC, "FBref: Football statistics and history," 2024. [Online]. Available: <https://fbref.com/en/> (accessed 2026-05-24).
- [22] Transfermarkt, "National teams market values," 2026, manual snapshot. [Online]. Available: <https://www.transfermarkt.com> (accessed 2026-05-24).
- [23] EloRatings.net, "World football Elo ratings," 2024. [Online]. Available: <https://www.eloratings.net/> (accessed 2026-05-24).
- [24] T. Akiba, S. Sano, T. Yanase, T. Ohta, and M. Koyama, "Optuna: A next-generation hyperparameter optimization framework," in *Proc. 25th ACM SIGKDD Int. Conf. on Knowledge Discovery and Data Mining*, 2019, pp. 2623–2631, doi: <https://doi.org/10.1145/3292500.3330701>.
- [25] C. J. Clopper and E. S. Pearson, "The use of confidence or fiducial limits illustrated in the case of the binomial," *Biometrika*, vol. 26, no. 4, pp. 404–413, 1934, doi: <https://doi.org/10.1093/biomet/26.4.404>.