

Predicción Probabilística del Mundial de Fútbol FIFA 2026 mediante Gradient Boosting y Simulación Monte Carlo

David Deras

Curso de Especialización en Machine Learning

Repositorio: github.com/daiv05/fifa-world-cup-model

dc19019@ues.edu.sv

Resumen—Se presenta un sistema end-to-end para estimar la probabilidad de campeonato de cada una de las 48 selecciones que disputarán la Copa Mundial de la FIFA 2026 bajo el nuevo formato de 12 grupos. El pipeline integra cuatro fuentes heterogéneas (resultados internacionales 1872–2024, *Expected Goals* de StatsBomb, valor de mercado de Transfermarkt y ranking FIFA histórico) para construir siete características que alimentan tres clasificadores multiclase (Regresión Logística, XGBoost y LightGBM) entrenados con ponderación por decaimiento temporal exponencial y rebalanceo de clases. El mejor modelo (XGBoost calibrado isotónicamente) obtiene un Brier $\approx 0,17$ sobre un conjunto de prueba temporal y se acopla a un motor Monte Carlo de 10,000 iteraciones que respeta el reglamento 2026 (2 primeros de grupo + 8 mejores terceros, desempates puntos→DG→GF, definición por penales). Los intervalos de confianza de Clopper–Pearson sitúan a un grupo reducido de selecciones históricamente fuertes entre los favoritos. Una sección dedicada discute las limitaciones del modelo: equipos debutantes sin historial, cobertura parcial de xG y ausencia de modelado estructural de lesiones.

Index Terms—Fútbol, predicción probabilística, XGBoost, Monte Carlo, ranking ELO, Mundial 2026, calibración isotónica.

I. INTRODUCCIÓN

La Copa Mundial de la FIFA 2026 estrena el mayor cambio estructural de su historia: 48 selecciones repartidas en 12 grupos de 4, de los cuales avanzan los dos primeros lugares más los ocho mejores terceros, totalizando 32 equipos en la fase eliminatoria. El torneo agrega una ronda adicional (*Round of 32*) y eleva el total de partidos a 104 [11]. Este cambio reglamentario invalida directamente los modelos calibrados sobre formatos de 32 equipos y motiva un rediseño del motor de simulación.

Este trabajo introduce un sistema reproducible para estimar la probabilidad de título de cada selección. Las contribuciones son: (i) un pipeline de datos automatizado que combina cuatro fuentes históricas y modernas; (ii) un benchmark de tres clasificadores multiclase entrenados con *time decay* exponencial y calibración isotónica sobre un *hold-out* temporal; (iii) un motor Monte Carlo que implementa fielmente el reglamento 2026, incluyendo el desempate de los ocho mejores terceros y la simetría local/visitante con excepción para los anfitriones; (iv) una validación histórica sobre el Mundial 2022 sin *data*

leakage y un análisis de sensibilidad a lesiones (−30 % del valor de plantilla).

II. TRABAJO RELACIONADO

El árbol genético de la predicción futbolística parte del modelo Poisson de Maher [16] y de su refinamiento Dixon–Coles [2], que captura la correlación de marcadores bajos. El sistema de puntuación Elo [1] proporciona una métrica de fuerza relativa actualizable partido a partido, hoy estandarizada para selecciones nacionales. Trabajos más recientes combinan *Random Forest* con *ratings* de equipo para Mundiales y Eurocopas [15]. La popularización de XGBoost [3] y LightGBM [4] ha desplazado la frontera hacia modelos de *gradient boosting*, mientras que SHAP [5] permite interpretar sus predicciones. Para evaluar la calibración de probabilidades el estándar son el Log-Loss y el Brier score [6], complementados con calibración isotónica o de Platt [8], [9].

III. PIPELINE DE DATOS

Los datos crudos se descargan o cargan en `src/data/` y se materializan en `data/raw/`; la limpieza y la unión producen `data/processed/features.csv`. El pipeline integra tres categorías de fuentes (datasets históricos, APIs y scraping), resumidas en la Tabla I.

Nota: revisar y sincronizar con `data/processed/model_evaluation.csv`.

Fuente principal de resultados. El dataset de Mart Jürisoo [12] disponible tanto en GitHub como en Kaggle [17] constituye el núcleo del entrenamiento con $\approx 49,000$ partidos internacionales (1872–2024). Se complementa con los resultados de Mundiales 1974–2022 [19] y los datos estructurados de openfootball [21] para validar el formato del torneo. El ranking FIFA histórico [18] y el dataset de probabilidades base WC 2026 basado en Elo [20] se usan como referencia cruzada para calibrar el feature `ranking_diff`.

Fuentes de estadísticas avanzadas. Los xG históricos provienen del *open data* de StatsBomb [13], consumido vía `statsbombpy`. Para selecciones con escasa cobertura StatsBomb se consultan FBref [24] (xA, presiones, progresiones de pase) y API-Football [22] (estadísticas de jugadores en ligas europeas). Football-Data.org [23] complementa el seguimiento de los convocados en ligas domésticas. Los ratings Elo se

Tabla I
FUENTES DE DATOS INTEGRADAS EN EL PIPELINE

Fuente	Contenido	Cobertura
<i>Datasets históricos</i>		
martj42 [12], [17]	Resultados internacionales	1872–2024, $\approx 49\,000$ partidos
FIFA Ranking [18]	Posición y puntos	1993–2023, ≈ 210 selecc.
WC Matches [19]	Partidos Mundiales	1974–2022
WC 2026 Base-line [20]	Prob. base Elo WC 2026	48 equipos, fase grupos
openfootball [21]	Fixtures y resultados WC	Todas las ediciones
StatsBomb [13]	xG por equipo	109 selecc.
<i>APIs (datos actualizados)</i>		
API-Football [22]	Estadísticas de jugadores, xG	Ligas europeas
Football-Data.org [23]	Ligas domésticas de convocados	Europa y América
<i>Web scraping</i>		
FBref [24]	xA, presiones, progresiones	Internac. y ligas
Transfermarkt [14]	Valor de mercado plantilla	60 selecc., snapshot
EloRatings.net [25]	ELO histórico verificado	≈ 200 selecc.

contrastan con EloRatings.net [25], cuyo sistema dinámico es considerado más preciso que el ranking FIFA estático. El valor de mercado de las plantillas se obtiene con un *snapshot* manual de Transfermarkt [14].

Limpieza y unión. El proceso incluye: estandarización de nombres de países a un *canonical name* ($USA \rightarrow United States$), deduplicación por (*date*, *home*, *away*), geocodificación de sedes con *geopy* (distancia 0 cuando falla), *forward-fill* del ranking FIFA entre publicaciones e imputación del xG con la media global ($\approx 1,2$) para selecc. sin cobertura StatsBomb.

IV. INGENIERÍA DE CARACTERÍSTICAS

Se construyen siete características justificadas tanto teóricamente como mediante EDA (Tabla II). La Fig. 2 ilustra la dinamica del ELO en cinco selecciones representativas; la Fig. 4 muestra colinealidad alta entre *elo_diff* y *ranking_diff* ($r \approx 0,84$), mientras que el resto de pares se mantiene en niveles moderados.

IV-A. Decaimiento temporal y ponderación de clases

Cada partido contribuye al entrenamiento con un peso

$$W(t) = e^{-\lambda \Delta t} \cdot c_{y_i}, \quad \lambda = 2 \times 10^{-3} \text{ días}^{-1}, \quad (1)$$

donde Δt son los días entre la fecha del partido y la más reciente del dataset, y c_{y_i} es el peso *balanced* de *sklearn* sobre la etiqueta $y_i \in \{H, E, V\}$. Esto corrige el desbalance

Tabla II
CARACTERÍSTICAS DEL MODELO Y SU JUSTIFICACIÓN

Feature	Justificación
<i>elo_diff</i>	ELO local – ELO visitante; métrica dinámica superior al ranking FIFA estático [1]
<i>squad_value_diff</i>	$\log(\text{val}_L) - \log(\text{val}_V)$; proxy de calidad de plantilla
<i>xg_avg_for</i>	xG prom. a favor: local – visitante; eficiencia ofensiva
<i>xg_avg_against</i>	xG prom. en contra: local – visitante; solidez defensiva
<i>travel_dist_home</i>	km de la capital del local a la sede; fatiga de viaje
<i>travel_dist_away</i>	Ídem para el visitante
<i>ranking_diff</i>	$\text{rank}_V - \text{rank}_L$; saltos del ranking FI-FA




Figura 1. Distribución de *elo_diff* por clase de resultado (H/E/V). La separación monotónica entre las tres distribuciones respalda el poder predictivo del feature.




Figura 2. Evolución del rating ELO para cinco selecciones representativas a lo largo de cuatro décadas.

natural $H \approx 49\%$, $E \approx 21\%$, $V \approx 30\%$ (Fig. 3) y prioriza la señal reciente. Los pesos se renormalizan por su media para que el aprendizaje permanezca a escala unitaria.

V. MODELADO

El problema se formula como clasificación multiclase a nivel de partido $\{H, E, V\}$. Se entrenan tres modelos: Regresión Logística multinomial (*baseline*, con *StandardScaler*), XGBoost (*multi:softprob*) y LightGBM. La búsqueda de hiperparámetros emplea Optuna [10] con 100 *trials* y *TimeSeriesSplit* ($n = 5$) interno sobre el conjunto de entrenamiento, optimizando *neg_log_loss*. La Fig. 5 resume la importancia SHAP agregada (mean |SHAP|) y mues-




Figura 3. Distribución de la variable objetivo. El desbalance hacia la clase *Local* motiva la ponderación `class_weight=balanced`.

Tabla III
SPLIT TEMPORAL Y USO DE CADA CONJUNTO

Conjunto	Filtro	Uso
Train	date < 2021-01-01	LogReg, XGBoost, LightGBM
Validación	2021-01-01 ≤ date < 2022-01-01	Calibración isotónica
Test	date ≥ 2022-01-01	Evaluación final

tra que `elo_diff` domina, seguido por `ranking_diff`; `travel_distance_away` aporta en un segundo nivel, mientras que `squad_value_diff` queda por debajo de lo esperado.

V-A. División temporal del dataset

Se evita rigurosamente el *data leakage* mediante un split estrictamente temporal (Tabla III). La calibración isotónica del XGBoost se ajusta sobre la franja 2021 (validación) para no contaminar el conjunto de prueba.

Doble pipeline. Para validar el Mundial 2022 sin leakage se re-ejecuta el entrenamiento con `cutoff = 2022-01-01`, produciendo `xgboost_pre2022.joblib`. Cuando este `cutoff` vacía el conjunto de validación temporal, se activa un *fallback* 85/15 que reserva el último 15 % temporal del *train* para la calibración.

VI. MOTOR DE SIMULACIÓN DEL TORNEO

El motor (`src/simulation/`) ejecuta $N=10,000$ realizaciones del torneo completo (104 partidos $\times N=1,04 \times 10^6$ partidos simulados). Cada partido i, j pasa por las siguientes etapas:

1. **Probabilidades simétricas.** Salvo cuando uno de los equipos es anfitrión jugando en su país, se promedia $P(i \text{ vs } j)$ con la inversión de $P(j \text{ vs } i)$ para eliminar el sesgo home/away heredado del dataset.

Tabla IV
MÉTRICAS DE EVALUACIÓN SOBRE TEST TEMPORAL (≥ 2022)

Modelo	Log-Loss ↓	Brier ↓
LogReg	0,8894	0,1741
XGBoost	0,8948	0,1755
LightGBM	0,9005	0,1772
XGBoost-Cal	1,0242	0,1716

2. **Marcador y outcome.** El *outcome* $\{H, E, V\}$ se sortea con las probabilidades del modelo. En fase de grupos se generan goles $g_i \sim \text{Poisson}(\mu_i)$, $g_j \sim \text{Poisson}(\mu_j)$ con μ basado en xG a favor/en contra, y el marcador se ajusta para ser coherente con el outcome (desempates por DG/GF).
3. **Fase de grupos.** 12 grupos de 4; clasifican los dos primeros más los 8 mejores terceros, con desempates puntos $\rightarrow$ diferencia de goles $\rightarrow$ goles a favor según el reglamento FIFA 2026 [11].
4. **Eliminatorias.** Round of 32 $\rightarrow$ Round of 16 $\rightarrow$ Cuartos $\rightarrow$ Semifinales $\rightarrow$ Final. Si hay empate tras los 90', la definición por penales se modela como Bernoulli(0,5).

Se contabilizan, por equipo, las veces que alcanza cada ronda y los intervalos de confianza al 90 % se calculan con el método binomial exacto de Clopper-Pearson [7] vía `scipy.stats.beta`.

VII. EVALUACIÓN

Se reportan Log-Loss y Brier score sobre el conjunto de prueba ($\text{date} \geq 2022$). Se evita *accuracy* por ser inadecuada para predicciones probabilísticas desbalanceadas [6]. La Tabla IV muestra que LogReg y XGBoost calibrado son competitivos; el XGBoost calibrado tiende a mejorar el Brier a costa de un Log-Loss algo mayor, el *trade-off* esperado al recalibrar probabilidades.

Validación histórica. El modelo `xgboost_pre2022` (entrenado exclusivamente con `date < 2022-01-01`) se evalúa sobre los partidos del Mundial 2022, sirviendo como prueba *out-of-time* sin contaminación. Los resultados numéricos se imprimen en consola al ejecutar `make evaluate`.

VIII. RESULTADOS DE LA SIMULACIÓN

La Tabla V lista el Top-10 de candidatos al título y la Tabla VI resume la progresión por fase de los tres anfitriones, ambos con intervalos Clopper-Pearson al 90 %.

Nota: revisar y sincronizar con `data/processed/simulation_results.csv`.

Nota: revisar y sincronizar con `data/processed/tournament_progression.csv`.

VIII-A. Análisis de sensibilidad a lesiones

Aunque las lesiones no se modelan estructuralmente, el script `src/analysis/sensitivity.py` aplica una perturbación de -30 % sobre `squad_value` para cada equipo del top-5 y re-ejecuta la simulación. La Tabla VII muestra que el efecto es modesto ($|\Delta| < 0,7$ pp en todos los casos), lo cual




Figura 4. Matriz de correlación de las siete características. Se observa colinealidad alta entre `elo_diff` y `ranking_diff`; el resto de pares se mantiene en rangos moderados.




Figura 5. Resumen SHAP agregado (mean |SHAP|) del XGBoost. `elo_diff` domina la contribución, con `ranking_diff` en segundo lugar y `travel_distance_away` en un tercer nivel.




Figura 6. Curvas de calibración. El XGBoost calibrado isotónicamente es el que más se aproxima a la diagonal ideal.

es consistente con la observación de que el feature `elo_diff` domina la importancia SHAP (Fig. 5).

Tabla V
TOP-10 CANDIDATOS A CAMPEÓN (10 000 ITERACIONES)

Equipo	P(Campeón)	IC 90 %
España	14,12 %	[13,55, 14,71]
Argentina	11,20 %	[10,68, 11,73]
Brasil	8,32 %	[7,87, 8,79]
Francia	8,01 %	[7,57, 8,47]
Inglaterra	6,30 %	[5,90, 6,71]
México	6,06 %	[5,67, 6,47]
Estados Unidos	5,69 %	[5,31, 6,09]
Japón	4,03 %	[3,71, 4,37]
Portugal	3,72 %	[3,41, 4,05]
Alemania	3,01 %	[2,73, 3,31]

Tabla VI
PROGRESIÓN POR FASE DE LOS ANFITRIONES (%, IC 90 %)

Fase	México	EE.UU.	Canadá
Round of 16	64,9	48,7	51,4
Cuartos	35,6	31,1	26,9
Semifinales	21,0	19,1	12,9
Final	11,6	10,3	5,6
Campeón	6,1	5,7	2,4

IX. LIMITACIONES

El modelo presenta cinco limitaciones reconocidas:

- Debutantes.** Equipos como Uzbekistán, Curazao o Cabo Verde tienen historial internacional escaso; su ELO se

Tabla VII
SENSIBILIDAD A UNA REDUCCIÓN DEL 30 % EN EL VALOR DE PLANTILLA

Equipo	Base %	Lesión %	Δ pp
España	14,12	13,91	-0,21
Argentina	11,20	10,51	-0,69
Brasil	8,32	8,69	+0,37
Francia	8,01	8,08	+0,07
Inglaterra	6,30	6,62	+0,32

inicializa con el valor neutro 1500 y converge lentamente, lo que probablemente *infla* su probabilidad relativa frente a rivales subestimados de la misma confederación.

2. **Cobertura xG.** El *open data* de StatsBomb [13] privilegia torneos UEFA/CONMEBOL; las selecciones de AFC, CAF y CONCACAF reciben un xG por defecto de 1,2, que es la media global. Esto subestima la varianza inter-equipos en estas confederaciones.
3. **Snapshot Transfermarkt.** El valor de mercado es una fotografía manual a una fecha fija (no *live scraping*); cambios posteriores (transferencias, retiros) no se reflejan hasta el siguiente *snapshot*.
4. **Geocodificación.** Cuando la sede del partido no es geocodificable se asigna `travel_distance = 0`, indistinguible de un campo neutro o de un partido en casa, lo que diluye levemente la señal de fatiga.
5. **Lesiones de última hora.** No hay modelado estructural de bajas individuales; el `sensitivity.py` es únicamente un *stress test* agregado sobre `squad_value`. Una baja clave en una posición específica (e.g., portero titular) tiene un impacto que el modelo no puede capturar.

X. REPRODUCIBILIDAD

El repositorio mantiene una arquitectura modular bajo `src/` (`data/`, `features/`, `models/`, `simulation/`, `analysis/`, `visualization/`), con CSVs versionables producidos en `data/processed/` y figuras en `reports/figures/`. Toda la cadena se reproduce con:

```
pip install -e .
make all      # features -> train -> evaluate
              # -> simulate -> sensitivity
streamlit run \
  src/visualization/dashboard.py
```

La cobertura de pruebas (`pytest tests/ -v`) valida la mecánica del ELO, la lógica de desempates de grupos y el muestreo Poisson de goles. Un *dashboard* Streamlit se publica en <https://fifa-world-cup-model.streamlit.app/>.

XI. CONCLUSIONES Y TRABAJO FUTURO

Se ha presentado un sistema reproducible para predecir la Copa Mundial 2026 que cumple con los requisitos planteados: múltiples fuentes limpias, siete características justificadas, *benchmark* de tres modelos con calibración temporal y un

motor Monte Carlo de 10,000 iteraciones fiel al nuevo reglamento. Las simulaciones ubican a selecciones tradicionalmente fuertes en el primer grupo de probabilidades, mientras que los anfitriones muestran una ventaja coherente sin distorsionar el escenario global.

Trabajo futuro: (i) incorporar un modelo Dixon–Coles [2] para los marcadores en lugar de Poisson independiente; (ii) reemplazar el *snapshot* Transfermarkt por un *scraper* programado; (iii) acelerar el bucle Monte Carlo con NumPy vectorizado o un binario en Rust invocado vía FFI, lo que permitiría escalar a $10^5 - 10^6$ iteraciones; y (iv) modelar lesiones a nivel de jugador integrando *features* de minutos disputados y posición.

REFERENCIAS

- [1] A. E. Elo, *The Rating of Chessplayers, Past and Present*. New York: Arco Publishing, 1978.
- [2] M. J. Dixon and S. G. Coles, “Modelling association football scores and inefficiencies in the football betting market,” *Journal of the Royal Statistical Society: Series C (Applied Statistics)*, vol. 46, no. 2, pp. 265–280, 1997.
- [3] T. Chen and C. Guestrin, “XGBoost: A scalable tree boosting system,” in *Proc. 22nd ACM SIGKDD Int. Conf. on Knowledge Discovery and Data Mining*, 2016, pp. 785–794.
- [4] G. Ke *et al.*, “LightGBM: A highly efficient gradient boosting decision tree,” in *Adv. Neural Inf. Process. Syst. (NeurIPS)*, vol. 30, 2017.
- [5] S. M. Lundberg and S.-I. Lee, “A unified approach to interpreting model predictions,” in *Adv. Neural Inf. Process. Syst. (NeurIPS)*, vol. 30, 2017.
- [6] G. W. Brier, “Verification of forecasts expressed in terms of probability,” *Monthly Weather Review*, vol. 78, no. 1, pp. 1–3, 1950.
- [7] C. J. Clopper and E. S. Pearson, “The use of confidence or fiducial limits illustrated in the case of the binomial,” *Biometrika*, vol. 26, no. 4, pp. 404–413, 1934.
- [8] J. C. Platt, “Probabilistic outputs for support vector machines and comparisons to regularized likelihood methods,” in *Advances in Large Margin Classifiers*, 1999, pp. 61–74.
- [9] A. Niculescu-Mizil and R. Caruana, “Predicting good probabilities with supervised learning,” in *Proc. 22nd Int. Conf. on Machine Learning (ICML)*, 2005, pp. 625–632.
- [10] T. Akiba, S. Sano, T. Yanase, T. Ohta, and M. Koyama, “Optuna: A next-generation hyperparameter optimization framework,” in *Proc. 25th ACM SIGKDD Int. Conf. on Knowledge Discovery and Data Mining*, 2019, pp. 2623–2631.
- [11] Fédération Internationale de Football Association, “FIFA World Cup 2026 competition format and regulations,” 2023, accessed 2026-05-24. [Online]. Available: <https://www.fifa.com/fifaplan/en/tournaments/mens/worldcup/canadamexicousa2026>
- [12] M. Jürisoo, “International football results from 1872 to 2024,” 2024. [Online]. Available: https://github.com/martj42/international_results
- [13] StatsBomb, “StatsBomb open data,” 2024. [Online]. Available: <https://github.com/statsbomb/open-data>
- [14] Transfermarkt, “National teams market values,” 2026, manual snapshot. [Online]. Available: <https://www.transfermarkt.com>
- [15] A. Groll, C. Ley, G. Schaubberger, and H. Van Eetvelde, “A hybrid random forest to predict soccer matches in international tournaments,” *J. Quant. Anal. Sports*, vol. 15, no. 4, pp. 271–287, 2019.
- [16] M. J. Maher, “Modelling association football scores,” *Statistica Neerlandica*, vol. 36, no. 3, pp. 109–118, 1982.
- [17] M. Jürisoo, “International football results from 1872 to 2023,” *Kaggle*, 2023. [Online]. Available: <https://kaggle.com/datasets/martj42/international-football-results-from-1872-to-2017>
- [18] cashncarry, “FIFA world ranking 1993–2023,” *Kaggle*, 2023. [Online]. Available: <https://www.kaggle.com/datasets/cashncarry/fifaworldranking>
- [19] I. Shahrukh, “FIFA world cup matches 1974–2022,” *Kaggle*, 2023. [Online]. Available: <https://www.kaggle.com/datasets/ibrahimshahrkh/fifa-world-cup-matches-19742022-dataset>
- [20] S. Zahran, “WC2026 match probability baseline dataset,” *Kaggle*, 2024. [Online]. Available: <https://www.kaggle.com/datasets/sarazahran/wc2026-match-probability-baseline-dataset>

- [21] openfootball contributors, “World cup data repository,” GitHub, 2024. [Online]. Available: <https://github.com/openfootball/worldcup>
- [22] RapidAPI / API-Football, “API-Football: Football statistics and live scores,” 2024. [Online]. Available: <https://rapidapi.com/collection/football-soccer>
- [23] Football-Data.org, “Football data and results,” 2024. [Online]. Available: <https://www.football-data.org/>
- [24] Sports Reference LLC, “FBref: Football statistics and history,” 2024. [Online]. Available: <https://fbref.com/en/>
- [25] EloRatings.net, “World football Elo ratings,” 2024. [Online]. Available: <https://www.eloratings.net/>